

EKONOMICKÁ UNIVERZITA V BRATISLAVE
NÁZOV FAKULTY

Evidenčné číslo:

VYUŽITIE NÁSTROJOV STROJOVÉHO UČENIA VO
FINANČNEJ ANALÝZE

Diplomová práca

EKONOMICKÁ UNIVERZITA V BRATISLAVE
NÁZOV FAKULTY

VYUŽITIE NÁSTROJOV STROJOVÉHO UČENIA VO
FINANČNEJ ANALÝZE

Diplomová práca

Študijný program: Data science v ekonómii
Študijný odbor: Ekonómia a manažment
Školiace pracovisko: Katedra operačného výskumu a ekonometrie
Vedúci záverečnej práce: prof. Mgr. Juraj Pekár, PhD.

Bratislava 2026

Bc. Luka Kuzyk

Čestné vyhlásenie

Vyhlasujem, že som celú záverečnú prácu vypracoval samostatne s použitím uvedenej odbornej literatúry.

Bratislava, 04. apríla 2026

.....
vlastnoručný podpis

Pod'akovanie

ABSTRAKT

PRIEZVISKO, Meno: *Názov záverečnej práce.* – Ekonomická univerzita v Bratislave. Názov fakulty; názov katedry. – Vedúci/vedúca záverečnej práce (pri dizertačných prácach školiteľ/školiteľka): tituly pred menom, meno a priezvisko, tituly za menom. – Bratislava: skratka fakulty (napr. NHF EU), rok, počet strán (napr. 70 s.)

Záverečná (habilitačnej) práce je vypracovaná na tému Cieľom záverečnej práce bolo

.....

..... Jednotlivé časti záverečnej práce boli zamerané na

.....

Výsledkom riešenia danej problematiky je

.....

Kľúčové

slová:

.....

ABSTRACT

Znenie slovenského abstraktu uviesť aj v anglickom, prípadne inom cudzom jazyku vrátane identifikačných údajov na začiatku abstraktu.

Obsah

Úvod	11
1. Súčasný stav problematiky doma a v zahraničí	12
1.1. Finančná analýza prostredníctvom strojového učenia	12
1.2. Aplikácia a porovnanie ML modelov pri predikcii cien akcií	12
1.2.1. Lineárne modely a stromové algoritmy	13
1.2.2. Ansámblové metódy a metóda podporných vektorov	14
1.2.3. Predikcia finančnej tiesne a bankrotu ako klasifikačná úloha	15
1.3. Interpretovateľnosť modelov strojového učenia vo financiách	16
1.4. Vplyv technických indikátorov a dátového šumu na presnosť	16
2. Cieľ práce	18
3. Metodika a metodológia práce	19
3.1. Výskumné ciele a formulácia problému	19
3.2. Zber dát a výber aktív	19
3.2.1. Technické a štatistické indikátory	19
3.2.2. Alternatívne dáta a trhové sentimenty	20
3.2.3. Redukcia dimenzionality	21
3.3. Algoritmy strojového učenia	21
3.3.1. Lineárne modely	21
3.3.2. Stromové modely a Gradient Boosting	22
3.3.3. Stacking a meta-učenie	23
3.4. Validácia a optimalizácia hyperparametrov	23
3.4.1. Časová krížová validácia	23
3.4.2. Bayesiánska optimalizácia (Optuna)	24
3.5. Hodnotiace metriky a interpretovateľnosť	25
3.5.1. Kvantifikácia chybovosti	25
3.6. Interpretovateľnosť modelov	25
4. Výsledky práce	27
4.1. Dátová základná	27
4.1.1. Zdrojové dáta	27
4.1.2. Výber akciového titulu	28

4.1.3.	Trhové indexy	28
4.2.	Predspracovanie	29
4.2.1.	Úprava časových radov	29
4.2.2.	Tvorba technických indikátorov	30
4.2.3.	Makroekonomické a iné faktory	30
4.2.4.	Výber premenných	30
4.3.	Metodika a modelovanie	31
4.3.1.	Algoritmy strojového učenia	31
4.3.2.	Validácia modelov	32
4.3.3.	Obchodná stratégia	32
4.4.	Popis výsledkov a ich interpretácia pre spoločnosť Apple	33
4.4.1.	Regresná predikcia na nasledujúci deň	35
4.4.2.	Klasifikačná predikcia na nasledujúci deň	37
4.4.3.	Analýza bodových odchýlok	39
4.4.4.	Distribúcia chýb predikcií	40
4.4.5.	Stabilita predikcií v čase	41
4.4.6.	Korelácia modelových signálov	42
4.4.7.	Výkonnosť, celkové výnosy stratégií a vývoj kapitálovej krivky	44
4.4.8.	Mesačné výnosy	46
4.4.9.	Analýza dôležitosti vstupných premenných	48
4.4.10.	Rozloženie dôležitosti atribútov podľa jednotlivých modelov	49
4.4.11.	Lineárna korelácia atribútov s cieľovou premennou	50
4.4.12.	Agregovaná dôležitosť podľa kategórií dát	52
4.4.13.	Interpretácia modelu prostredníctvom SHAP hodnôt	53
4.4.14.	Globálna dôležitosť parametrov pomocou SHAP hodnôt	55
4.4.15.	Čiastkové zhrnutie výsledkov pre akciu Apple	56
4.5.	Popísanie výsledkov	57
5.	Záver	58
	Zoznam použitej literatúry	59
	Prílohy	61

Obr. 1	Vizualizácia regresnej predikcie ceny na piatok 20. februára 2026 pre akciu AAPL	35
Obr. 2	Štatistická chybovosť a smerová presnosť regresných modelov pre APPL	36
Obr. 3	Obr. 10 Celkové výnosy stratégií modelov naviazaných na akciu AAPL.....	45
Obr. 4	Obr. 12 Priemerná dôležitosť TOP 20 atribútov naprieč stromovými modelmi.....	48
Obr. 5	Obr. 13 Dôležitosť TOP 10 atribútov v rozklade na konkrétne stromové modely.	50
Obr. 6	Obr. 14 Pearsonova korelácia TOP 20 najdôležitejších atribútov s výnosom nasledujúceho dňa pre AAPL.....	51
Obr. 7	Obr. 15 Celkový vplyv jednotlivých skupín atribútov na predikcie modelov pre AAPL.	52
Obr. 8	SHAP Summary plot (Bee Swarm) pre najvplyvnejšie premenné na datasete AAPL	54
Obr. 9	Obr. 17 Priemerná absolútna hodnota SHAP (Globálna dôležitosť) pre AAPL.....	56

Úvod

1. Súčasný stav problematiky doma a v zahraničí

Súčasný globálne finančné trhy sú charakteristické vysokou volatilitou, nelinearitou a stochastickým správaním, čo z predikcie cien finančných aktív robí jednu z najzložitejších analytických úloh. Táto kapitola analyzuje aktuálny stav vedeckého poznania v oblasti aplikácie algoritmov strojového učenia (Machine Learning - ML) vo finančnej analýze, so špecifickým zameraním na komparatívne štúdie modelov využívaných na predikciu cien akcií.

1.1. Finančná analýza prostredníctvom strojového učenia

Integrácia algoritmov strojového učenia do oblasti finančnej analytiky predstavuje jednu z najdôležitejších etáp vývoja súčasnej kvantitatívnej ekonómie. Po desaťročia zostávala fundamentálnym základom finančnej teórie Hypotéza efektívneho trhu, ktorá predpokladá, že všetky dostupné informačné toky sa okamžite a úplne premietajú do cien finančných aktív. Podľa tejto teórie sa budúce cenové pohyby riadia princípom „náhodnej prechádzky“ (random walk), čo robí systematické predpovedanie trhu nemožným (López de Prado, 2018).

Pred príchodom pokročilých techník strojového učenia sa investori a analytici pri analýze časových radov cien akcií spoliehali dominantne na tradičné štatistické a ekonometrické modely, akými sú napríklad modely ARIMA (Auto-Regressive Integrated Moving Average) alebo GARCH (Cibuľa, 2022). Hoci sú tieto modely vysoko efektívne v stabilnom prostredí a poskytujú dobrú štatistickú interpretovateľnosť, ich fundamentálnym obmedzením je predpoklad linearity a stacionarity dát (Shi, 2024). Na reálnych trhoch plných štrukturálnych šokov však tieto predpoklady často zlyhávajú.

Obrovský skok vo výkone počítačov a dostupnosť historických trhových dát spôsobili, že za posledné desaťročie sa do popredia dostalo strojové učenie. Výhoda týchto algoritmov je, že sa dokážu učiť z historických dát sami a dokážu zachytiť aj dynamické, zložité a nelineárne zmeny na trhu bez toho, aby sme ich museli na to zložito programovať (Cibuľa, 2022). V súčasnosti sa vedecký výskum zameriava hlavne na porovnávanie klasických prístupov so stromovými modelmi, napríklad Random Forest a XGBoost, a architektúrami neurónových sietí prispôbených na časové rady, najmä LSTM (Jin & Yi, 2023).

1.2. Aplikácia a porovnanie ML modelov pri predikcii cien akcií

Z analýzy nedávnych štúdií vyplýva, že autori vo svojich výskumoch spravidla hľadajú optimálnu rovnováhu medzi presnosťou predikcie – vyhodnocovanou najčastejšie pomocou metrík ako stredná kvadratická chyba (MSE), odmocnina strednej kvadratickej chyby (RMSE) a

stredná absolútna chyba (MAE) – a výpočtovou efektivitou daného modelu. V odbornej literatúre sa na predikciu cien akcií najčastejšie využíva komparácia lineárnych modelov, modelov založených na metóde podporných vektorov (SVR) a ansámblových stromových techník.

1.2.1. Lineárne modely a stromové algoritmy

Deswal vo svojom výskume porovnával modely lineárnej regresie a algoritmu Random Forest (RF) pri predikcii zatváracích cien akcií technologickej spoločnosti Apple. Z výsledkov jeho experimentu vyplynulo, že na konkrétnom súbore dát bez prítomnosti extrémneho trhového šumu preukázal model klasickej lineárnej regresie lepšiu schopnosť prispôbiť sa cenovému trendu. Autor dospel k záveru, že lineárna regresia dosiahla v tomto špecifickom prípade nižšie hodnoty chýb MSE a RMSE a na stabilných úsekoch vykazovala rýchlejšiu odozvu na cenové zmeny ako Random Forest (Deswal, 2023).

K podobným záverom dospeli aj Andrika a Rahardi, ktorí vo svojej štúdii zameranej na predikciu akcií po ich rozdelení zistili, že pri jasne definovaných stabilných trendoch môžu byť jednoduchšie regresné prístupy adekvátne presné a predovšetkým výpočtovo nenáročné v porovnaní s komplexnými algoritmi (Andrika & Rahardi, 2025). Tento fenomén detailne skúmal aj Wang, ktorý zbieral a analyzoval dáta šiestich technologických gigantov (tzv. skupiny FAANG+M) na burze NASDAQ v rokoch 2015 až 2024 a testoval modely lineárnej regresie, Random Forest a XGBoost s cieľom eliminovať trhové fluktuácie. Výsledky jeho výskumu ukázali, že v tomto špecifickom kontexte dosahovala lineárna regresia optimálne výsledky, zatiaľ čo zložitejšie modely zaostávali. Autor tento výsledok vysvetľuje existenciou pozitívnej korelácie medzi jednoduchosťou modelu a kvalitou výsledku v stabilnom prostredí, pričom upozorňuje, že zložitosť stromových modelov často vedie k nechcenému problému s preučeníím na historických dátach (Wang, 2025).

Ďalšia porovnávacia štúdia (Zubair a kol., 2024) potvrdila, že komplexný rozbor výkonnostných metrík je absolútne nevyhnutný pre správny výber modelu, pričom voľba medzi lineárnou regresiou, Random Forest a XGBoost by mala vždy zohľadňovať predovšetkým mieru nelinearity samotných dát. Na domácich dátach tento prístup overovala štúdia publikovaná v MDPI (2020), ktorá podrobne analyzovala výkonnosť modelov na rozsiahlom súbore dát slovenských priemyselných podnikov. Autori postavili do priameho kontrastu klasickú logistickú regresiu proti učiacim sa algoritmom, reprezentovaným najmä modelom Random Forest. Z výsledkov výskumu vyplynulo, že algoritmy strojového učenia prekonal tradičnú regresnú analýzu vo viacerých metrikách vrátane celkovej presnosti a parametrov LogLoss, čo

dokumentuje ich schopnosť lepšie pracovať s komplexnými a nelineárnymi finančnými dátami (MDPI, 2020).

1.2.2. Ansámblové metódy a metóda podporných vektorov

Pre trhy a akcie s vyššou mierou volatility sa však do popredia jednoznačne dostávajú ansámblové techniky. Tieto modely, reprezentované najmä algoritmami Random Forest (RF) a eXtreme Gradient Boosting (XGBoost), fungujú na princípe agregácie viacerých slabších rozhodovacích stromov (prediktorov) do jedného robustného celku. Vo svojej štúdii Jin a Yi analyzovali vplyv technických indikátorov a zdôraznili, že agregované metódy vďaka zabudovaným mechanizmom odolnosti voči preučeniu výrazne prekonávajú samostatné rozhodovacie stromy (Jin & Yi, 2023).

Súperenie dvoch najrozšírenejších ansámblových prístupov bolo predmetom štúdií Panggabean a Widyasari kde autori realizovali výskum zameraný na porovnanie modelu Random Forest a Support Vector Regression (SVR). Zistili, že Random Forest dosiahol pri predikcii mimoriadne vysokú presnosť (R^2 skóre na úrovni 0.997) a preukázal sa ako oveľa robustnejší nástroj pri analýze trhových dát v nestabilných podmienkach v porovnaní s modelom SVR, ktorý vykazoval vyššiu mieru chybovosti meraní cez MAE a RMSE (Panggabean & Widyasari, 2023). Podobné výsledky zaznamenali aj Raya a kol. (2022), ktorí na základe hodnotenia metriky MAE skonštatovali, že spomedzi testovaných algoritmov, vrátane SVR a klasických prístupov, preukázal práve Random Forest najlepšie predikčné schopnosti.

Na druhej strane, iná empirická štúdia (MDPI, 2024), ktorá modelovala a predpovedala denné ceny akciového indexu MSI 20, priniesla odlišnú perspektívu. Autori v nej testovali SVR aj XGBoost, pričom pri ladení hyperparametrov využili techniku Grid Search. Výsledky preukázali, že po dôkladnej optimalizácii parametrov dokázal model SVR dosiahnuť vynikajúcu predikčnú presnosť a v niektorých prípadoch dokonca prekonať iné, bežne využívané ansámblové algoritmy.

Ďalšie porovnanie prináša vo svojej práci Wang, ktorý aplikoval široké spektrum metód strojového učenia, vrátane lineárnej regresie, SVR, K-Nearest Neighbors (KNN) a ansámblových metód Bagging, AdaBoost, XGBoost na akcie spoločností z rôznych sektorov, konkrétne Intel, Coca-Cola a Exxon Mobil. Z jeho analýzy vyplýva zistenie, že neexistuje jeden univerzálny predikčný model. Kým pre technologický sektor s nelineárnymi výkyvmi vykazovali najvyššiu presnosť metódy Bagging a XGBoost, pre iné sektory s odlišnou dynamikou cien, ako je potravinársky priemysel, sa úspešne uplatnili aj odlišné algoritmy. Uvedená štúdia zároveň

podčiarkuje dôležitosť správneho ladenia hyperparametrov a selekcie vstupných premenných, ktoré sú kritické pre maximalizáciu výkonu akéhokoľvek ML modelu (Wang, 2023).

1.2.3. Predikcia finančnej tiesne a bankrotu ako klasifikačná úloha

Okrem predikcie samotných cien akcií sa metódy klasického strojového učenia vo finančnej analýze intenzívne porovnávajú aj v klasifikačných úlohách, akými je napríklad predikcia finančnej tiesne podnikov. Tento smer analýzy bezprostredne súvisí s vývojom fundamentálnej hodnoty akcií podniku. Kim a kol. (2020) vo svojej prehľadovej štúdii definujú, že popri štatistických modeloch tvoria jadro moderných varovných systémov práve klasifikátory podporných vektorov (SVM) a rozhodovacie stromy. Autori tiež zdôrazňujú, že úspešný model strojového učenia pre predikciu bankrotu musí byť schopný jasne indikovať hlavnú príčinu zlyhania.

V rozsiahlej porovnávacej štúdii Kristanti a kol. (2024) testovali schopnosť modelov predpovedať úpadok na základe účtovných a finančných pomerových ukazovateľov u spoločností na indonézskej burze cenných papierov. Autori skúšali modely SVM, KNN, Random Forest a XGBoost. Vzhľadom na to, že finančné dáta o bankrotoch bývajú výrazne skreslené v prospech určitej triedy, implementovali techniku prevzorkovania SMOTE. Výsledky tohto výskumu jasne potvrdili dominanciu stromových ansámblových metód. Klasifikátory XGBoost a Random Forest dosiahli po aplikácii vyvažovacej techniky presnosť presahujúcu 96 %, čím výrazne prekonal modely založené na vzdialenosti (KNN) a vektoroch (SVM) v schopnosti spoľahlivo identifikovať anomálie v účtovných výkazoch (Kristanti a kol., 2024).

Podobne úspešné nasadenie zaznamenali aj inovatívne architektúry ako LightGBM. Vo svojom výskume zameranom na identifikáciu rizika zlyhania korporátnych dlhopisov aplikoval Zhao (2025) model LightGBM v spojení s optimalizačným algoritmom NSGA-II. Empirické testovanie ukázalo, že tento optimalizovaný ansámblový prístup dosahuje presnosť nad 85 % a prekonáva tak tradičné metódy, pričom exceluje vo vyhodnocovaní kritických rysov, akými sú ukazovatele obratu pohľadávok a ziskové marže.

Zhrnutie súčasnej odbornej literatúry naznačuje, že hoci pre akcie s nízkou volatilitou a stabilným trendom môže za určitých okolností používať aj klasická lineárna regresia, pre zachytenie komplexnej dynamiky, nelineárnych vzťahov a spracovanie rozsiahleho množstva technických indikátorov sa aktuálnym zlatým štandardom v oblasti klasického strojového učenia stávajú modely XGBoost a Random Forest.

1.3. Interpretovateľnosť modelov strojového učenia vo financiách

Narastajúca komplexita ansámblových algoritmov, akými sú XGBoost a Random Forest, prináša so sebou vážny metodologický problém ich interpretovateľnosti. Tieto metódy často v odbornej literatúre figurujú ako modely typu “čierna skrinka”. V kontexte finančného sektora a regulovaného auditu je neakceptovateľné prijímať investičné rozhodnutia výhradne na základe výstupov algoritmu bez pochopenia samotného rozhodovacieho procesu. Regulačné orgány aj investori vyžadujú presnú kvantifikáciu toho, aké konkrétne vstupné premenné viedli model k danej predikcii. Z tohto dôvodu sa integrálnou súčasťou aplikovaného strojového učenia stala analýza interpretovateľnosti.

Na riešenie problému transparentnosti sa v súčasnosti najčastejšie aplikujú analytické metódy ako SHAP (SHapley Additive exPlanations) a LIME (Local Interpretable Model-agnostic Explanations). Tieto matematické prístupy vychádzajú z teórie kooperatívnych hier a umožňujú presne vyčíslieť príspevok každého nezávislého parametra k finálnemu výsledku predikcie. V medzinárodnom výskume sa tejto problematike venoval napríklad Agarwal, ktorý vo svojej štúdii demonštroval, že aplikácia hodnôt SHAP na predikčný model XGBoost nielenže neznižuje jeho vynikajúcu predikčnú presnosť, ale poskytuje finančným analytikom kľúčový pohľad na to, ktoré konkrétne technické či fundamentálne indikátory najviac ovplyvňujú výslednú cenu aktíva (Agarwal, 2024). Zabezpečenie interpretovateľnosti modelov strojového učenia prostredníctvom týchto techník sa tak ukazuje ako nevyhnutný predpoklad pre ich dôveryhodné a bezpečné nasadenie do reálnej hospodárskej a obchodnej praxe.

1.4. Vplyv technických indikátorov a dátového šumu na presnosť

Dôležitým faktorom, ktorý zásadným spôsobom ovplyvňuje presnosť a výber ML modelov, je kvalita vstupných dát a množstvo aplikovaných technických indikátorov. Deep a kol. (2024) hodnotili výkonnosť regresných modelov Random Forest pri vysokofrekvenčnej predikcii cien akcií s využitím dátových sád obohatených o technické indikátory, akými sú Bollingerove pásma, exponenciálny kľzavý priemer či Fibonacciho návraty. Hoci implementácia týchto indikátorov vylepšila výkonnostné metriky očistené o riziko na tréningových dátach, modely následne výrazne zlyhávali pri generalizácii na testovacích vzorkách. Analýza dôležitosti príznakov odhalila, že primárne znaky založené výlučne na cene dosahovali vo vysokofrekvenčnom obchodovaní konzistentne lepšie výsledky ako odvodené technické indikátory, ktoré často generovali falošné signály a prispievali k preučeniu.

Pre redukciu tohto šumu a zlepšenie presnosti viacerí autori navrhujú konštrukciu hybridných prístupov aj v rámci samotného klasického strojového učenia. Nageswaran a Sankarasubramanian (2026) vo svojom výskume testovali historické akciové dáta (Open, High, Low, Close) a zistili, že kombinácia ansámblových stromových modelov a modelov založených na vektorových vzdialenostiach prináša väčšiu stabilitu a odolnosť voči trhovému šumu než použitie akéhokoľvek samostatného klasifikátora.

2. Ciel prace

Hlavným cieľom diplomovej práce je aplikácia vybraných algoritmov strojového učenia pri predikcii vývoja cien finančných aktív a následná analýza porovnania ich predikčnej presnosti v dynamickom trhovom prostredí. Parciálnym cieľom v teoretickej časti je teoretické vymedzenie základných princípov a odborných pojmov nevyhnutných pre vytvorenie uceleného teoretického rámca v oblasti využívania analytických modelov vo financiách. Súčasťou tohto teoretického prieskumu je aj zhodnotenie aktuálneho stavu domáceho a zahraničného vedeckého poznania prostredníctvom rešerše odbornej literatúry so zameraním na doterajšie empirické porovnanie lineárnych, vektorových a ansámblových metód.

Analytická časť diplomovej práce je zameraná na praktické testovanie a vyhodnotenie stanovených predikčných modelov priamo na historických dátach globálnych akciových trhov. Modelovanie bude prebiehať v programovacom prostredí jazyka Python, pričom sa s využitím špecializovaných knižníc pre dátovú vedu zrealizuje pedspracovanie údajov a natréovanie algoritmov, akými sú lineárna regresia, Random Forest a XGBoost. Preto za čiastkové ciele v praktickej časti považujeme nasledovné ciele:

- **Zber** a systematické pedspracovanie relevantných historických dát o vývoji cien vybraných akciových titulov prostredníctvom finančných rozhraní.
- **Konštrukcia** a implementácia vybraných technických indikátorov za účelom rozšírenia a obohatenia pôvodnej dátovej sady o premenné zachytávajúce trend a volatilitu.
- **Implementácia** a tréovanie vybraných modelov strojového učenia s cieľom definovať ich optimálne hyperparametre pre účely predikcie časových radov.
- **Vyhodnotenie** predikčnej sily a presnosti jednotlivých algoritmov na základe kvantitatívnych metrík, akými sú stredná absolútna chyba, stredná kvadratická chyba a koeficient determinácie.
- **Porovnanie** výkonnosti regresných, vektorových a stromových metód v rôznych trhových podmienkach s cieľom identifikovať najvhodnejší predikčný model.
- **Aplikácia** metód vysvetliteľnej umelej inteligencie pre detailnú interpretáciu toho, akým spôsobom jednotlivé technické premenné ovplyvňujú finálne rozhodnutia modelov.

Naplnením týchto cieľov budeme schopní nielen identifikovať najpresnejší a efektívny algoritmus pre predikciu akciových trhov, ale aj poskytnúť transparentný a interpretovateľný rámec, ktorý podporí empiricky podložené investičné rozhodovanie v hospodárskej praxi.

3. Metodika a metodológia práce

3.1. Výskumné ciele a formulácia problému

Zavádzanie metód strojového učenia do finančnej analýzy si vyžaduje jasné stanovenie výskumného problému a postupný prechod od tradičných ekonometrických prístupov k moderným dátovým modelom. Súčasné trhy sú totiž mimoriadne volatilné, plné nelineárnych vzťahov a náhodných výkyvov. Práve preto patrí predikcia cien finančných aktív medzi najkomplexnejšie výzvy, ktorým dnes analytici čelia.

V minulosti sa predikcie trhu spoliehali najmä na hypotézu efektívneho trhu (EMH). Tá predpokladá, že všetky dostupné informácie sa okamžite a úplne premietnu do ceny aktíva. Z toho vychádza princíp „náhodnej prechádzky“ (random walk) – myšlienka, že najlepším odhadom zajtrajšej ceny je tá dnešná a dlhodobu prekonávať trh je nemožné. Strojové učenie však tento striktný pohľad mení. Aj keď sú finančné dáta plné šumu, moderné algoritmy v nich dokážu odhaliť skryté nelineárne vzorce, na ktoré klasické ekonometrické modely ako ARIMA či GARCH jednoducho nestačia. Práve na prekonanie týchto limitov v práci navrhujeme predikčný systém založený na učení s učiteľom.

3.2. Zber dát a výber aktív

Surové cenové dáta nesú len obmedzenú informačnú hodnotu a modelom často nestačia na pochopenie trhovej dynamiky. Aby algoritmus dokázal rozoznať vznikajúce trendy, cykly a zmeny volatility, pôvodný dataset sa umelo rozširuje o nové premenné v procese nazývanom príznakové inžinierstvo (feature engineering). Tento proces zahŕňa konštrukciu technických indikátorov, integráciu externých dát a následný inteligentný výber tých najrelevantnejších parametrov.

3.2.1. Technické a štatistické indikátory

Do predikčného systému sú algoritmicky implementované viaceré overené trhové indikátory, z ktorých každý pomáha zachytiť inú vlastnosť analyzovaného aktíva:

1. **RSI (Relative Strength Index):** Tento oscilátor meria rýchlosť a zmenu cenových pohybov, vďaka čomu model dokáže identifikovať, či je trh krátkodobo prekúpený alebo naopak predaný. Počíta sa na základe pomeru priemerných ziskov a priemerných strát (označovaných ako RS) za stanovené časové okno:

$$RSI = 100 - \frac{100}{1 + RS}$$

2. **MACD (Moving Average Convergence Divergence):** Ide o indikátor zameraný na sledovanie zotrvačnosti a hybnosti trendu. Pomáha odhaliť zmeny v sile trendu sledovaním vzťahu medzi dvoma kľavými priermi. Vypočíta sa ako priamy rozdiel medzi krátkodobým (12-dňovým) a dlhodobým (26-dňovým) exponenciálnym kľavým priemerom (EMA) ceny:

$$MACD = EMA_{12}(Cena) - EMA_{26}(Cena)$$

3. **Bollingerove pásma (Bollinger Bands):** Tieto pásma poskytujú modelu informáciu o aktuálnej trhovej volatilitate. Skladajú sa zo stredného kľavého priemeru (typicky 20-dňového) a dvoch okrajových pások. Okrajové pásy sú dynamicky umiestnené nad a pod stredným priemerom na základe pripočítania, resp. odpočítania násobku aktuálnej smerodajnej odchýlky.
4. **ATR (Average True Range):** Zatiaľ čo Bollingerove pásma reagujú na uzatváracie ceny, indikátor ATR meria skutočnú čistú volatilitu trhu tak, že zohľadňuje aj cenové medzery medzi jednotlivými obchodnými dňami. Modelu poskytuje absolútnu hodnotu priemerného denného pohybu ceny.

3.2.2. Alternatívne dáta a trhové sentimenty

Ceny akcií sa nevyvíjajú vo vákuu; reagujú na aktuálne udalosti, náladu v spoločnosti a globálne trendy. Z tohto dôvodu sa systém neobmedzuje len na cenové grafy, ale integruje aj alternatívne dátové zdroje, špecificky dáta o trendoch vo vyhľadávaní (Google Trends) a informácie z agregátorov správ.

Sledovanie frekvencie vyhľadávania určitých kľúčových slov poskytuje cenný indikátor spotrebiteľského a investorského záujmu ešte predtým, ako sa tento záujem prejaví na burze.¹ Napríklad vyhľadávanie slova „iPhone“ priamo súvisí s očakávaním tržieb spoločnosti Apple, kým frekvencia vyhľadávania skratky „AI“ odzrkadľuje širší investičný sentiment a ošial' okolo technologického sektora. Systém do modelu zaraďuje aj kľúčové slová ako „elections“ (voľby), pretože pomáhajú zachytiť makroekonomickú neistotu a zmeny v rizikovom apetíte investorov. Tieto externé sentimentálne premenné dodávajú stromovým aj lineárnym modelom kontext, ktorý z čistých čísel nie je možné odvodiť.

3.2.3. Redukcia dimenzionality

Pridaním všetkých dostupných technických indikátorov, ich rôznych časových oneskorení a alternatívnych sentimentálnych dát vzniká mimoriadne široký dataset. Ak by sa všetky tieto premenné naraz vložili do učiaceho sa algoritmu, nevyhnutne by to viedlo k preučeniu. Model by začal hľadať falošné pravidlá aj v náhodnom informačnom šume.

Na riešenie tohto problému sa v systéme aplikuje Lasso regresia, ktorá funguje ako zabudovaný filter pre výber vlastností. Lasso je forma lineárnej regresie s L1 regularizáciou. Upravuje štandardnú chybovú funkciu modelu tak, že do nej pridáva penalizačný člen. Tento člen prísne trestá model za každý použitý parameter (váhu), pričom trest je úmerný absolútnej hodnote tejto váhy:

$$Cost = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^m |w_j|$$

V tomto vzorci λ predstavuje silu penalizácie a w_j sú koeficienty (váhy) jednotlivých vstupných premenných. Dôvod, prečo táto konkrétna rovnica redukuje dimenzionalitu, spočíva v tvare L1 penalty. Na rozdiel od iných metód, ktoré váhy iba znižujú, Lasso vďaka absolútnej hodnote dokáže zraziť váhy menej užitočných indikátorov presne na nulu. Systém tak automaticky identifikuje a vyradí premenné, ktoré neprispievajú k presnosti predikcie. Výsledkom je menší, čistejší a oveľa stabilnejší súbor prediktorov, ktorý sa následne posúva hlavným algoritmom strojového učenia.

3.3. Algoritmy strojového učenia

V predikčnom rámci sa nevyužívame iba jeden typ algoritmu. Namiesto toho systematicky porovnávame viaceré prístupy, od priamočiarych lineárnych modelov až po matematicky komplexné stromové štruktúry. Cieľom tohto porovnania je zistiť, či vyššia zložitosť modelu skutočne prináša lepšie výsledky na reálnych finančných trhoch.

3.3.1. Lineárne modely

Lineárne modely sú výpočtovo nenáročné, vysoko interpretovateľné a v stabilných obdobiach s jasným trendom často prekvapivo presné.

- **Lineárna regresia:** Tento algoritmus sa snaží preložiť dátami priamku tak, aby súčet štvorcov odchýlok skutočných hodnôt od tejto priamky bol čo najmenší. Ide o jednoduché váženie vstupných parametrov bez akejkoľvek zabudovanej ochrany proti preučeniu.

- **ElasticNet:** Keďže finančné indikátory sú často navzájom vysoko korelované (napríklad rôzne typy kľzavých priemerov), klasická lineárna regresia zlyháva. ElasticNet tento problém rieši elegantným matematickým kompromisom – do výpočtu chyby pridáva súčasne L1 penalizáciu (Lasso, ktorá nepotrebné premenné úplne vyradí) aj L2 penalizáciu (Ridge, ktorá váhy iba znižuje a stabilizuje). Vďaka tomu model zvláda zložité, prepojené dáta oveľa lepšie.
- **Logistická regresia (Logistic Regression):** Hoci má v názve slovo regresia, ide o klasifikačný algoritmus. Používame ho výhradne vtedy, keď predpovedáme len smer trhu (rast alebo pokles). Namiesto odhadu ceny vracia model pravdepodobnosť, že trh stúpne. Túto transformáciu dosahuje aplikovaním logistickej funkcie (sigmoidy) na lineárny výstup. Ak je výsledná pravdepodobnosť vyššia ako zadaný prah (najčastejšie 0,5), systém vygeneruje nákupný signál.

3.3.2. Stromové modely a Gradient Boosting

Pre zachytenie nelineárnych, nečakaných a prudkých zmien (akými sú napríklad trhové krízy), sa do architektúry zapájajú ansámblové metódy. Tie nepracujú len s jedným pravidlom, ale spájajú rozhodnutia desiatok až stoviek čiastkových stromov.

- **Náhodný les:** Tento model stavia na myšlienke „múdrosti davu“. Vybuduje veľké množstvo nezávislých rozhodovacích stromov, pričom každý strom sa učí len na náhodnom výseku dát a má k dispozícii len náhodnú podmnožinu indikátorov. Pri konečnej predikcii sa všetky stromy „hlasovaním“ zložia do jedného výsledku. Tento prístup výborne potláča šum a zabraňuje preučeniu.
- **XGBoost:** Extrémny gradientný boosting k problému pristupuje inak. Nestavia stromy nezávisle, ale postupne za sebou. Každý nový strom v sekvencii je matematicky zameraný výlučne na to, aby opravil chyby, ktoré urobili všetky stromy pred ním. Obrovská sila XGBoostu vo finančných aplikáciách spočíva v jeho vstavanej regularizácii priamo do účelovej funkcie, ktorú algoritmus minimalizuje:

$$Obj = \sum_{i=1}^n L(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

Tu funkcia L meria rozdiel medzi realitou a odhadom modelu. Druhá časť rovnice, Ω je regularizačný člen, ktorý prísne trestá model za to, ak stavia príliš zložité a hlboké stromy.

XGBoost tak pri každom kroku hľadá dokonalý balans – učí sa presne, ale zároveň zostáva natoľko jednoduchý, aby vedel generalizovať svoje vedomosti na nové dni na burze.

3.3.3. Stacking a meta-učenie

Pre využitie silných stránok viacerých algoritmov súčasne a potlačenie ich individuálnych slabín sa navrhuje implementácia pokročilej architektúry zvanej stacking (z angl. stacked generalization). V tejto architektúre nepôsobia základné modely izolovane, ale tvoria prvú vrstvu predikčného systému.

Proces funguje nasledovne:

1. **Tvorba meta-príznakov:** Základné modely sa netrénujú priamočiaro na celých dátach. Namiesto toho sa využíva vnútorná krížová validácia. Model sa natrénuje na časti dát a urobí predikciu pre zvyšnú časť, ktorú počas tréningu nevidel, tzv. Out-of-Fold predikcie. Týmto spôsobom sa pre každý deň v histórii získajú nezávislé cenové odhady od základných modelov. Tieto odhady sú objektívne, pretože modely nemali prístup k správnej odpovedi vopred.
2. **Meta-učenie:** Z týchto stĺpcov odhadov sa vytvorí nový dataset. Tento dataset následne vstupuje do finálneho nadradeného modelu, tzv. meta-learnera.
3. **Korekcia predsudkov:** Meta-learner sa neučí z pôvodných trhových dát, učí sa to, akú váhu a dôveru má priznať jednotlivým základným modelom. Ak sa napríklad historicky zistí, že Random Forest má tendenciu podhodnocovať prepady, zatiaľ čo XGBoost na ne reaguje presne, nadradený model túto nuansu matematicky zachytí a priradí odhadu z XGBoostu v príslušných trhových situáciách vyššiu váhu. Týmto prepojením systém dosahuje vyššiu stabilitu.

3.4. Validácia a optimalizácia hyperparametrov

Každý z modelov vyžaduje pre svoje optimálne fungovanie špecifické nastavenia (hyperparametre). Ladenie a otestovanie ich výkonnosti však vo financiách ukrýva zásadné metodologické nástrahy, čo navrhovaná architektúra striktne ošetruje.

3.4.1. Časová krížová validácia

V bežných úlohách dátovej vedy sa výkonnosť modelov testuje pomocou náhodnej K-násobnej krížovej validácie (Random K-Fold). Dáta sa jednoducho náhodne premiešajú a rozdelia na trénovacie a testovacie balíčky. Vo finančnej analýze časových radov je takýto prístup neprípustnou chybou. Ak by sa náhodne vybrali dni, model by sa pri predikcii včerajšej ceny mohol učiť z dát z nasledujúceho týždňa. Tento fenomén sa označuje ako únik dát alebo

skreslenie z nahliadnutia do budúcnosti. Model natrénovaný týmto spôsobom by vykazoval výborne výsledky v testoch, no pri nasadení v praxi by okamžite zlyhal a priniesol finančné straty.

Z tohto dôvodu metodológia nariaďuje použitie časovej krížovej validácie. Tento prístup zaručuje, že sa nikdy neporuší kauzalita a prirodzený tok času.³ Postupuje sa metódou rozširujúceho sa okna:

- **1. iterácia:** Model sa učí napríklad na dátach z rokov 2018–2020 a otestuje sa výhradne na roku 2021.
- **2. iterácia:** Trénovacie okno sa zväčší. Model sa učí na rokoch 2018–2021 a testuje sa na roku 2022.
- **3. iterácia:** Tréning prebieha na rokoch 2018–2022 a testuje sa na roku 2023.

Tento postup verne simuluje to, ako model prijíma nové informácie na reálnom trhu. Schopnosť učiť sa na minulosti a testovať prísne iba na bezprostrednej budúcnosti zaručuje, že hodnotiace metriky budú reflektovať skutočnú predikčnú silu systému.

3.4.2. Bayesiánska optimalizácia (Optuna)

Otázkou pri nasadzovaní algoritmov zostáva výber ich vnútorných nastavení. Pre stromové modely je potrebné určiť napríklad presný počet stromov alebo ich maximálnu hĺbku. Tieto hyperparametre nie je vhodné nechávať na náhodu.

Zaužívanou, no výpočtovo neefektívnou praxou je tzv. Grid Search, ktorý hrubou silou skúša všetky zadané kombinácie parametrov. Návrh predikčného systému preto počíta s pokročilejšou optimalizáciou, s využitím moderných knižníc pre Bayesiánsku optimalizáciu, akou je napríklad framework Optuna.

Tento prístup stavia na algoritme TPE (Tree-structured Parzen Estimator). Na rozdiel od Grid Search, ktorý zabúda na predchádzajúce pokusy, si Bayesiánska optimalizácia ukladá históriu toho, ako sa model správal. Postupne si stavia vlastný pravdepodobnostný model toho, ktoré oblasti hyperparametrov fungujú dobre a ktoré nie. Ak zistí, že hĺbka stromu väčšia ako 10 neustále vedie k preučeniu a zlým výsledkom na validačnej sade, túto oblasť prestane skúmať. Ušetrený výpočtový čas inteligentne investuje do jemného ladenia parametrov v tých zónach, ktoré sa javia ako sľubné. Vďaka tomuto prístupu je možné nájsť výkonnejšie modely za zlomok celkového strojového času.

3.5. Hodnotiace metriky a interpretovateľnosť

Na posúdenie modelov sú potrebné matematické kritériá, ktoré presne vyčíslia chybovosť predikcií a poskytnú vysvetlenie k rozhodovaciemu procesu algoritmu.

3.5.1. Kvantifikácia chybovosti

Pre regresnú časť systému sa na hodnotenie využívajú klasické chybové metriky:

- **Stredná kvadratická chyba (MSE):** Metrika počíta priemer štvorcov rozdielov medzi tým, čo model predpovedal $\hat{y}_i$, a tým, čo sa skutočne stalo na trhu y_i . Tým, že sa rozdiel umocňuje na druhú, MSE veľmi prísne, až neproporčne trestá model za akékoľvek veľké zlyhania v predikcii.

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- **Odmocnina strednej kvadratickej chyby (RMSE):** Keďže MSE je vyjadrená v štvorcových jednotkách, jej absolútna hodnota je pre analytika ťažšie interpretovateľná. RMSE z tohto výsledku urobí odmocninu, vďaka čomu sa chybovosť vráti do pôvodných jednotiek (napríklad priamo do percentuálnych bodov výnosu).

$$RMSE = \sqrt{MSE}$$

Pri klasifikačnom prístupe bežná metrika presnosti (Accuracy) neposkytuje celkový obraz. Preto sa pri optimalizácii vyhodnocuje aj metrika nazývaná Log Loss (logaritmickej strata). Log Loss je vynikajúca v tom, že nemeria len to, či model uhádol smer, ale penalizuje ho za to, ako veľmi sa pri zlom odhade mýlil vo svojej miere istoty. Ak si bol model na 99 % istý, že akcie porastú, no ony na druhý deň klesli, Log Loss ho za túto falošnú sebaistotu potrestá tvrdšie, než keby si model nebol istý a svoju predikciu by ohodnotil len na 51 %.

3.6. Interpretovateľnosť modelov

Jednou z najväčších kritík pokročilých ansámblových algoritmov je ich netransparentnosť, kvôli ktorej sa často označujú ako modely typu „čierna skrinka“. Vo finančnom sektore je však neakceptovateľné robiť rozhodnutia bez pochopenia toho, prečo systém generuje daný signál.

Na riešenie tohto problému sa v práci navrhuje aplikácia metodiky SHAP (SHapley Additive exPlanations). Táto metóda má korene v teórii kooperatívnych hier a matematicky prerozdeľuje celkový výsledok medzi jednotlivých "hráčov".

SHAP hodnoty odpovedajú na fundamentálnu otázku: *Aké konkrétne premenné posunuli dnešnú predikciu modelu preč od jeho dlhodobého priemerného odhadu?*

Namiesto toho, aby analytik dostal len globálnu dôležitosť premenných, SHAP vypočíta lokálne príspevky pre každý jeden deň. Vďaka tomu je možné určiť, že predikovaný rast bol spôsobený napríklad prudkým nárastom indikátora RSI a zvýšeným vyhľadávaním špecifického kľúčového slova, pričom tento rast bol čiastočne utlmený negatívnym prekrižením kľúčových priemerov MACD. Tento rámec zaisťuje, že empirické zistenia aplikované v nasledujúcich kapitolách budú plne objektívne a transparentné.

4. Výsledky práce

V tejto kapitole sa zameriavame na praktickú aplikáciu navrhnutého predikčného systému na reálnych finančných dátach. Cieľom je overiť schopnosť zvolených modelov strojového učenia identifikovať nelineárne vzťahy a predpovedať budúci vývoj cien vybraných aktív. Postupne analyzujeme dátovú základňu, proces predspracovania vstupných premenných a následne prezentujeme dosiahnuté výsledky pre primárne skúmanú spoločnosť Apple Inc., ako aj pre ďalšie porovnávacie akcie.

4.1. Dátová základná

Základným predpokladom pre konštrukciu akéhokoľvek modelu strojového učenia vo financiách je robustný a konzistentný súbor dát. Dátová časť tohto projektu je navrhnutá modulárne tak, aby pokrývala nielen časové rady trhových cien danej spoločnosti, ale aj kontextuálne informácie o celkovom vývoji trhu a makroekonomických faktoroch.

4.1.1. Zdrojové dáta

Pre získavanie historických cenových údajov bola využitá knižnica `yfinance`, ktorá slúži ako aplikačné programovacie rozhranie poskytujúce priamy prístup k platforme Yahoo Finance. Hlavnou výhodou tohto prístupu je bezplatný, rýchly a stabilný prístup k denným historickým trhovým dátam. Stiahnuté dáta primárne obsahujú informácie o otváracjej cene (Open), najvyššej (High) a najnižšej (Low) cene dňa, uzatváracjej cene (Close) a dennom zobchodovanom objeme (Volume). Analýza pre všetky výpočty využíva takzvanú upravenú uzatváraciu cenu (Adjusted Close), ktorá do seba integruje vplyvy vyplácania dividend a delenia akcií (stock splits).

Analyzovaný časový horizont bol v konfiguračnom súbore softvérového prostredia stanovený na horizont posledných piatich rokov nazad. Tento kompromis predstavuje dlhé obdobie na zachytenie rôznych trhových podmienok – od stabilnej rastovej fázy, až po obdobia vysokej krízovej volatility. Zároveň tento časový rámec eliminuje prítomnosť príliš starých dát, pri ktorých by už vtedajšia štruktúra a mikroštruktúra trhu nemusela reflektovať jeho súčasné správanie. Z takto stiahnutých dát boli v procese čistenia odstránené chronologické duplicity a časové známky boli zjednotené do formátu UTC pre zabezpečenie plynulého zlučovania časových radov pochádzajúcich z viacerých časových pásiem.

Okrem klasických cenových formátov sme do projektu integrovali aj udalosti týkajúce sa termínov zverejňovania hospodárskych výsledkov podnikov (tzv. Earnings Dates), stiahnuté priamo prostredníctvom Yahoo Finance kalendára. Týmto krokom sme vytvorili podklad pre

zachytenie kalendárnych anomálií a špecifických udalostí. Súbor vstupov sme navyše obohatili o alternatívne indexy dopytu (data stiahnuté z Google Trends), ktorými monitorujeme intenzitu vyhľadávania výrazov ako „AI“, „iPhone“, prípadne politických kľúčových slov a makroekonomických pojmov (inflácia, nezamestnanosť). Tieto data využívame primárne ako ukazovateľ spotrebiteľského a trhového sentimentu.

4.1.2. Výber akciového titulu

Z hľadiska programátorskej i vedomostnej architektúry sme model navrhli prísne dynamicky, vďaka čomu vieme celú jeho tréningovú a testovaciu fázu automaticky adaptovať na takmer akýkoľvek voľne dostupný a platný cenný papier na trhu. Pre potreby detailnej demonštrácie vyvinutého prístupu a ako našu hlavnú výskumnú vzorku sme si však primárne zvolili spoločnosť Apple Inc., ktorá je obchodovaná na burze pod tickerom AAPL.

Tento výber reflektoval hneď niekoľko našich kvantitatívnych požiadaviek. Akcie spoločnosti Apple dlhodobo patria medzi najlikvidnejšie a najviac obchodované inštrumenty vo svetovom meradle. Vzhľadom na ich gigantickú trhovú kapitalizáciu a masívne percento inštitucionálneho držania akcií prakticky nepodliehajú prudkým a náhodným cenovým manipuláciám jednotlivcov. Táto plynulosť cenotvorby nám následne do uvažovaného modelu strojového učenia dodáva veľmi dôležitý „čistý signál“, nezaťažený likviditným šumom malých spoločností. Prostredníctvom implementovaného algoritmu sme rovnako namodelovali testy aj na iných spoločnostiach s odlišnou dynamikou – od defenzívnych spotrebiteľských firiem (The Coca-Cola Company), cez finančné holdingy (JPMorgan Chase), až po volatilnejšie technologické podskupiny (Nvidia). Detailné sumáre výsledkov a prierezovú analýzu týchto backtestov sme vizualizovali a vložili do záverečnej prílohovej časti práce s cieľom uchovať jadrový text sústredený na analýzu fungovania algoritmu na príklade prioritného aktíva.

4.1.3. Trhové indexy

Keďže vývoj ceny akéhokoľvek samostatného cenného papiera nikdy neprebíha v absolútnom trhovom vákuu, v modelovaní sme zohľadnili makroekonomické korelácie a ich preliv na konkrétnu akciu. Za týmto účelom sme surový datasúbor cenových atribútov hlavného aktíva obohatili o doplnujúce, takzvané prierezové faktory. V predskriptovacej fáze dynamicky sťahujeme a cez spoločný časový index mapujeme nasledujúcu trojicu inštrumentov:

- **S&P 500** (index s tickerom ^GSPC): Tento index, ktorý zahŕňa 500 najväčších amerických spoločností, sme v práci použili ako hlavný ukazovateľ celkového vývoja

trhu. Do modelu vstupujú jeho percentuálne zmeny, ktoré slúžia ako základná referencia pre zachytenie globálneho akciového sentimentu.

- **VIX** (index volatility $\sqrt{\text{VIX}}$): Známy aj ako „index strachu“ (CBOE Volatility Index), odzrkadľuje očakávania trhu ohľadom cenových výkyvov v nasledujúcich 30 dňoch na základe opcií na index S&P 500. Jeho náhle nárasty pomáhajú modelu včas identifikovať riziko hlbokých trhových výpredajov.
- **Nasdaq-100 ETF** (fond s tickerom QQQ): Keďže analyzovaná spoločnosť Apple je dominantným hráčom v technologickom sektore, fond QQQ sme využili ako sektorový benchmark. Oddelenie vplyvu celkového trhu (S&P 500) od technologického sektora umožnilo klasifikátorom presnejšie zachytiť špecifickú dynamiku a dopyt po technologických akciách.

Logická konštrukcia týchto dátových spojení – ktorú sme skompletizovali vložení termínov publikovania výsledkov a analýzou nálad z Google Trends a Google News - efektívne tvorí hrubú vstupnú vrstvu. Architektúra algoritmu týmto momentom zhromažďuje jednotnú maticu tabuľkových dát obsahujúcich všetky nevyhnutné informácie, pripravenú k následnej modifikácii a výpočtu odlišných derivovaných zložitejších premenných.

4.2. Predspracovanie

Kvalita a formát vstupných dát priamo ovplyvňujú výsledky akéhokoľvek modelu strojového učenia. V tejto fáze projektu sme stiahnuté surové údaje očistili a matematicky transformovali do formátu, z ktorého dokážu modely jednoduchšie analyzovať hľadané vzorce.

4.2.1. Úprava časových radov

Finančné časové rady na dennej báze bežne obsahujú šum a chýbajúce hodnoty, napríklad v dňoch štátnych sviatkov. Surové uzatváracie ceny sme hneď v prvom kroku previedli na spojitý logaritmické výnosy. Tento krok sme spravili preto, lebo samotné ceny nesplňajú predpoklad stacionarity, zatiaľ čo denné zmeny (výnosy) majú oveľa stabilnejšie štatistické vlastnosti.

Taktiež sme časové rady z rôznych zdrojov (akcie, opčné indexy, Google Trends) zoradili podľa zhodného dátumu do jednej tabuľky. Na ošetrovanie prípadných chýbajúcich hodnôt, kedy jeden inštrument nebol obchodovaný, použil náš skript metódu dopĺňania poslednou známou hodnotou a následne spätného dopĺňania. Aby sme modelu v žiadnom prípade nezabránili „nazeraniu do budúcnosti“, pri dátach o nálade z Google Trends sme aplikovali bezpečný časový posun v hodnote 7 dní. Modely tak vždy videli len správy a vyhľadávania, ktoré už reálne v danom dni existovali.

4.2.2. Tvorba technických indikátorov

Zistili sme, že samotná cena z predchádzajúceho dňa väčšinou nenesie celú informáciu o trhovom trende. Rozhodli sme sa preto naprogramovať sadu pomocných premenných – technických indikátorov, ktoré sa v kvantitatívnom tradingu pravidelne využívajú. Medzi indikátory, z ktorých sa modely mali možnosť učiť, sme zaradili:

- **Trendové indikátory:** Jednoduché kĺzavé priemery (SMA) s periódou 5 a 20 dní, ako aj indikátor MACD, ktorý kombinuje 12, 26 a 9-dňové exponenciálne priemery.
- **Oscilátory a momentum:** Index relatívnej sily (RSI) s oknom 14 dní, Stochastický oscilátor (%K a %D) a Commodity Channel Index (CCI) s periódou 20 dní. Vypočítali sme aj naše vlastné hodnoty momenta tak, že sme aktuálnu cenu vydělili cenou spred 5, respektíve 10 dní.
- **Miera volatility:** Bollingerove pásma, použili sme 2 smerodajné odchýlky od 20-dňového priemeru, Priemerný skutočný rozsah, ATR za 14 dní, a nami zvolenú 5-dňovú realizovanú volatilitu vypočítanú z rozptylu logaritmických výnosov.
- **Predošlé záznamy a štatistika:** Do stĺpcov sme doplnili predchádzajúce hodnoty denných logaritmických výnosov historicky posunuté od 1 až po 30 dní. Navyše sme pre každý obchodný deň dopočítali kĺzavú mieru šikmosti a špicatosti za posledný mesiac (20 dní), čím sme sledovali zmeny v tvare rozdelenia výnosov.

4.2.3. Makroekonomické a iné faktory

Do úvahy sme brali aj vývoj širšieho okolia. Časové rady spomínaných indexov (S&P 500, technologický QQQ fond a VIX) sme rovnako previedli na percentuálne zmeny a posunuli o 1, 2 a 3 obchodné dni dozadu. Z časových prvkov dátumu sme extrahovali bežné kalendárne údaje - presný mesiac v roku a konkrétny deň v týždni. Vďaka tomu modely dostali možnosť vnímať prípadnú trhovú sezónnosť. Pre zachytenie zvýšeného záujmu verejnosti sme vytvorili aj binárnu premennú, podľa ktorej model vedel identifikovať, či sa v danom týždni publikujú kvartálne hospodárske výsledky analyzovanej firmy.

4.2.4. Výber premenných

Kombináciou všetkých zdrojov sme získali vyše 50 rôznych stĺpcov a údajov pre každý deň. Keď však model sleduje príliš veľké množstvo vstupov, stáva sa zraniteľným voči javu nazývanému pretrénovanie, pri ktorom si začne pamätať trhovú šum a stráca schopnosť

predpovedať nové dáta. Na zredukovanie počtu premenných na tie najdôležitejšie sme v Pythone zvolili Lasso regresiu, tzv. L1 regularizácia.

Pred samotným výberom sme všetky údaje v stĺpcoch algoritmickejšie štandardizovali, aby premenné s diametrálne odlišnými mierkami, napríklad objem v desiatkach miliónov kusov oproti percentuálnej zmene ceny v desatinách percenta, vstupovali do porovnania rovnocenne. Lasso regresor s nastaveným umelým trestom α na hodnotu 0,0001 sme následne spustili na tréningových dátach. Jeho silnou stránkou je, že matematicky dokáže úplne vynulovať váhy tých premenných, ktoré pre predpoveď nemajú význam. Takýmto krokom sme z obrovského súboru vybrali len tie najvplyvnejšie premenné (maximálne 15), a až s týmto preriedeným, kvalitnejším súborom dát sme reálne pracovali pri tréňovaní konečných modelov.

4.3. Metodika a modelovanie

V tejto časti práce detailne popíšeme, aké konkrétne algoritmy strojového učenia sme v naprogramovanom systéme použili. Taktiež definujeme, akým spôsobom sme simulovali reálne trhové prostredie tak, aby boli naše testovacie výstupy úplne oddelené od budúcich informácií.

4.3.1. Algoritmy strojového učenia

V návrhu architektúry sme sa rozhodli testovať dva odlišné prístupy. Prvým bola regresia, pri ktorej algoritmus do budúcnosti odhaduje priamo presnú číselnú hodnotu budúceho výnosu akcií. Druhým bola klasifikácia, kde sa model iba snaží predikovať pravdepodobnosť toho, či trh na ďalší deň stúpne alebo klesne. Do testovania sme zaradili širšie spektrum modelov, pričom hlavnú váhu sme kladli na stromové algoritmy, ktoré dokážu účinne zachytávať nelineárne a komplexné vzťahy na trhu. Primárne sme pracovali s:

- **Random Forest:** Zostava nezávisle tréňovaných rozhodovacích stromov, ktorá v praxi veľmi dobre znižuje spomínané riziko pretrénovania.
- **XGBoost a Gradient Boosting:** Pokročilé sekvenčné systémy, v ktorých sa stromy v sieti učia nadväzovaním, takže každý nový strom priamo opravuje chyby toho predchádzajúceho.
- **Lineárne modely:** Sem sme zaradili Logistickú regresiu a ElasticNet, ktoré sme chceli predovšetkým využiť ako základnú odrazovú plochu pre porovnávanie s komplexnejšími systémami.

Na prepojenie ich silných stránok sme naprogramovali aj prepracované Stacking ansámble. Pri regresnom koncepte tento nadstavbový meta-model zozbieral hrubé predikcie z modelov

Random Forest, Gradient Boostingu a XGBoostu, vložil ich do finálneho učiaceho Ridge modelu a až ten vydal konečné rozhodnutie. Pred spustením tréningu sme vo všetkých fázach uplatnili dátové škálovanie, aby mala každá z početných premenných priemer nula a štandardnú odchýlku jedna. Na určenie presných nastavovacích hyperparametrov pre tieto stromy (napríklad hĺbka stromov, miera učenia) sme využili knižnicu Optuna, skrze ktorú skript automatizovane prechádzal stovky kombinácií a vyberal nastavenia s najnižšou historickou chybovosťou.

4.3.2. Validácia modelov

Pomerne častou, avšak závažnou metodologickou chybou v teórii financií je použitie náhodného rozdelenia tabuľky dát na tréningovú a testovaciu časť. V časových radoch tým dochádza k „nazeraniu do budúcnosti“ (tzv. data leakage), kedy sa model pri tréňovaní na historických cenách dostane aj k cenám budúcim. Aby sme toto logické pochybenie plne odstránili, do kódu sme naimplementovali dynamickú testovaciu techniku – takzvané kľzavé okno (Walk-Forward Validation).

Mechanizmus sme logicky navrhli nasledovne: vytvorili sme tréningové okno o veľkosti 1008 po sebe idúcich obchodných dní (čo je trhovú ekvivalent k približne štyrom kalendárnym rokom). Z týchto tréningových dát sa algoritmus vždy naučil všetky vzorce. Testovacie okno sme prísne ohraničili len na nasledujúcich budúcich 63 obchodných dní (ekvivalent jedného štvrťroka), pre ktoré model musel generovať nezávislé slepé predpovede presne deň po dni. Len čo vypršal testovací štvrťrok, celé 1008-dňové učiace okno sme v čase posunuli o 63 dní dopredu. Obmedzené modely sme úplne od základov na tomto posunutom úseku pretrénovali, čím sa stihli učiť z nových krízových udalostí. Celý cyklus roloval historickými dátami až po úplnú prítomnosť. Celou podstatou okna bolo tréňovanie kľúčovej cieľovej premennej systému - spojitý logaritmický výnos $T+1$ (prave len pre nasledujúci obchodný deň).

4.3.3. Obchodná stratégia

Presný matematický odhad trhu v reálnej praxi neznamena automaticky finančný zisk - odhad musí prekonať náklady a bežný dlhodobý rastový trend akcií. Výstupy modelov sme preto presmerovali do modulu pre simulovanú obchodnú stratégiu. Jej výsledky sme priamo konfrontovali s populárnou pasívnou stratégiou „Kúp a drž“ (Buy & Hold).

Nastavili sme jednoduché exekutívne pravidlá výhradne pre investora vyhľadávajúceho iba rast cien, tzv. Long-Only stratégia:

- **V prípade regresných modelov:** Kód automaticky vygeneroval nákupný signál výlučne vo chvíli, pokiaľ predídený logaritmický výnos modelu presiahol nastavenú signálnu

hranicu zisku (tzv. Threshold na úrovni 0,2 % denne). Zvyšné nedefinované obdobia systém chránil kapitál držaním hotovosti mimo náchylného trhu.

- **V prípade klasifikátorov:** Model spustil nákup, ak vyrátaná softvérová pravdepodobnosť kladného rastu cieľovej akcie bezpečne presiahla neutrálnu váhu 50 %, respektíve pre konzervatívnejšie riadenie na zisku sme požadovali až úroveň "veľkej istoty" nad prahom presných 55 %.

Pre záverečné vyhodnotenie sme v tomto balíku nasledovali len čistý kumulatívny výnos. Algoritmus počítal krivku rastu kapitálu v čase a aplikoval základné rizikové a pomerové ukazovatele, predovšetkým vývin miery bezpečnosti cez ukazovateľ akým je Sharpe ratio. Týmto krokom sme priradili modelom dôležitý kontext. Koniec koncov sme presne videli, či aplikované modely dokážu vytvoriť okrem laboratórnej zhody aj skutočnú ekonomickú odolnosť.

4.4. Popis výsledkov a ich interpretácia pre spoločnosť Apple

Hlavným výstupom nášho naprogramovaného machine learning systému je jednotný výstup generovaný pre každú analyzovanú spoločnosť. Softvér transformuje všetky vypočítané premenné, tabuľky presnosti a kľúčové vizualizácie do formátu prehľadného HTML dokumentu (napríklad `aapl_ml_report.html`). V tejto podkapitole postupne pozrieme prvky takéhoto automatizovaného reportu a na príklade technologickej spoločnosti - Apple Inc. (AAPL).

Ako sme naznačili v metodologickej časti, celá vizualizovaná finančná analýza tohto projektu je postavená na takzvanej „daily-signal threshold strategy“ (stratégii denného prahu signálu). Vstupné dáta pre trhové ceny aj všetky prislúchajúce vytvorené premenné nesú dennú frekvenciu. Týchto päť rokov stiahnutých historických dát plynulo prešlo naším algoritmom kľzavého okna, vďaka čomu sa stalo, že každý zapojený model vygeneroval v rámci sledovaného periódy vždy iba jednu čistú predikciu na nasledujúci skúšaný deň - očakávaný logaritmický výnos.

Prediktívna výkonnosť, na ktorú sa v nasledujúcich riadkoch pozeráme, je pre akciu AAPL testovaná na tzv. out-of-sample dátach - teda na časovom úseku, ktorý modely pri trénovaní nevideli. Tento finálny testovací horizont pokrýva presne 243 obchodných dní, začínajúc 4. marcom 2025 a končiac 19. februárom 2026. Všetky prezentované grafy a tabuľky odzrkadľujú simuláciu obchodovania výlučne v tomto časovom okne.

Výsledné zachytené úkony na grafoch sa v našich reportoch riadia nasledujúcimi nemennými pravidlami obchodovania:

- **BUY (Nákup):** V prípade, že odhadovaný denný výnos modelu spĺňal podmienky a bezpečne prekročil nami fixne stanovený prah zisku +0,2 %, algoritmus vygeneroval nákupný signál. To teoreticky predstavuje otvorenie dlhej pozície hneď s otvorením trhu a jej systematické uzatvorenie pre výber zisku či uznanie straty s koncom toho istého obchodného dňa.
- **HOLD / CASH (Držať hotovosť v bezpečí):** Pokiaľ model v ten daný deň zanalyzoval premenné tak, že očakával výnos hlboko pod našim prahom, prípadne jasný denný pokles, systém nereagoval a virtuálny kapitál v simulácii zostal neinvestovaný – skrytý mimo obvyklého trhového rizika.


Keďže náš systém pracuje výhradne s dennými trhovými dátami z platformy Yahoo Finance, učiaci model generuje na jeden obchodný deň vždy práve jeden smerodajný signál. Naše testovanie v reporte tým pádom neobsahuje žiadne zložité denné obchodovanie a ani postupné prikupovanie akcií v prípade straty. Softvér urobí pre nasledujúci deň iba jedno jasné a konečné rozhodnutie.

Pre prehľadnosť vizualizácií, grafov a tabuliek sme v práci využili nasledujúce skratky modelov strojového učenia:

- **LINEAR / LOGREG:** Klasická lineárna pre regresiu alebo logistická pre klasifikáciu regresia.
- **ELASTICNET:** Lineárny model kombinujúci L1 (Lasso) a L2 (Ridge) regularizáciu.
- **SGD:** Stochastic Gradient Descent - stochastický gradientný zostup.
- **RF:** Random Forest - algoritmus náhodného lesa.
- **EXTRATREES:** Extra Trees - viac randomizovaná verzia náhodného lesa na obmedzenie preučenia.
- **GBR:** Gradient Boosting Regressor.
- **XGB:** XGBoost - optimalizovaná verzia Gradient Boostingu.
- **STACK:** Stacking Ensemble - meta-model spájajúci predikcie viacerých algoritmov do jedného konečného rozhodnutia)

Predpona **CL_** (napríklad **CL_RF**) pri názve modelu indikuje jeho klasifikačnú verziu.

4.4.1. Regresná predikcia na nasledujúci deň



Obr. 1 Vizualizácia regresnej predikcie ceny na piatok 20. februára 2026 pre akciu AAPL

Obrázok č. 1 znázorňuje bodové predikcie regresných modelov na nasledujúci obchodný deň. Modrá krivka zobrazuje skutočný vývoj uzatváraciej ceny akcií Apple za posledných 30 dní. Na posledný reálny dátový bod priamo nadväzujú odhady jednotlivých modelov pre čas $t+1$. Keďže posledným hodnoteným trhovým dňom na grafe s uzatváracou cenou 260,55 USD bol štvrtok 19. februára 2026, prezentovaná modelová abstrakcia zobrazuje odhady uzatváracích cien presne pre nasledujúci aktívny obchodný deň – piatok 20. februára 2026. Vpravo hore v legende grafu sú tieto modely zoradené zostupne - od najvyššej po najnižšiu predikovanú cenu.

Na prezentovanom príklade vidíme obojsmerný rozptyl predikcií: zatiaľ čo modely ELASTICNET a STACK očakávajú rast z aktuálnej ceny 260,55 USD na úroveň 260,72 USD (ELASTICNET), respektíve 260,68 USD (STACK), všetky ostatné nasadené modely predikujú trhovú korekciu a pokles cien v rozmedzí od 256,02 USD (XGB) do 259,83 USD (LINEAR).

V ľavom hornom rohu sa nachádza informačný panel s konečným investičným odporúčaním a jeho odôvodnením. Toto zhrnutie predstavuje finálne rozhodnutie celého systému. Algoritmus ho negeneruje ako priemer všetkých modelov, ale preberá ho výhradne z takzvaného primárneho modelu – teda z toho algoritmu, ktorý na predošlých historických dátach preukázal najvyššiu smerovú presnosť (Raw DA). V tomto konkrétnom príklade zvolil systém ako primárny model algoritmus EXTRATREES.

Práve spomínaný rozptyl denných odhadov tvorí základnú potrebu prísneho vyhodnocovania spätnej výkonnosti. Odpoveď na otázku, prečo systém vybral ako lídra priamo model EXTRATREES a aká je historická miera spoľahlivosti týchto výpočtov oproti iným algoritmom, poskytuje detailný rozklad metrík. Ten je zdokumentovaný v tabuľke na Obrázku č. 2.

Model ^{↑↓}	RMSE ^{↑↓}	MAE ^{↑↓}	Raw DA ^{↑↓}	Confident DA [↓]	Coverage ^{↑↓}	Trades ^{↑↓}
EXTRATREES (Reg)	0.0203	0.0126	54.1%	57.4%	44.6%	108 / 242
SGD (Reg)	0.0210	0.0136	50.4%	54.0%	56.6%	137 / 242
<i>Buy & Hold</i>	—	—	53.2%	53.2%	100.0%	
GBR (Reg)	0.0210	0.0140	51.2%	52.5%	66.1%	160 / 242
LINEAR (Reg)	0.0217	0.0145	52.5%	52.5%	75.6%	183 / 242
XGB (Reg)	0.0206	0.0132	52.1%	50.7%	57.0%	138 / 242
RF (Reg)	0.0205	0.0132	47.9%	49.6%	51.7%	125 / 242
ELASTICNET (Reg)	0.0203	0.0126	52.5%	0.0%	0.0%	0 / 242
STACK (Reg)	0.0203	0.0126	52.5%	0.0%	0.0%	0 / 242

Obr. 2 Štatistická chybovosť a smerová presnosť regresných modelov pre APPL


Obrázok č. 2 poskytuje kompletný prehľad o štatistickej chybovosti (RMSE, MAE) a smerovej presnosti jednotlivých algoritmov v celom testovacom období - 242 obchodných dní pre zvolenú akciu. V prvých dvoch stĺpcoch sa nachádzajú štandardné regresné metriky RMSE (Root Mean Square Error) a MAE (Mean Absolute Error). Tieto štatistické ukazovatele merajú veľkosť odchýlky predikovaného logaritmickeho výnosu od skutočnej trhovej reality. Ich absolútne hodnoty sú prirodzene nízke - napríklad hodnota MAE 0,0126 pri modeli EXTRATREES znamená, že sa model pri odhade denného výnosu v priemere mýlil len o 1,26 %.

Modely EXTRATREES, ELASTICNET a STACK preukázali na testovacej vzorke najnižšiu plošnú chybovosť. Naopak, základná lineárna regresia (LINEAR) zaznamenala najvyššie odchýlky (RMSE 0,0217 a MAE 0,0145). Pri spracovávaní finančných časových radov predstavujú aj takéto drobné zníženia chybovosti výrazný dôkaz o schopnosti vyspelejších algoritmov, ako sú práve Extra Trees, lepšie filtrovať skrytý trhový šum.

Z hľadiska obchodnej výkonnosti je okrem samotnej chybovosti dôležitá aj miera správnosti odhadnutého smeru. Zatiaľ čo metrika Raw DA vyjadruje všeobecnú úspešnosť modelu v uhádnutí smeru trhu (rast alebo pokles), kľúčovým ukazovateľom pre skutočné nasadenie do obchodnej stratégie je stĺpec Confident DA. Ten agreguje úspešnosť predikcií modelu iba v tých dňoch, v ktorých model prekročil prísny ziskový prah +0,2 % a skutočne vstúpil do obchodu.

Tabuľka navyše vykazuje parameter Coverage, ktorý identifikuje absolútny počet aktívnych obchodných dní s uskutočnenými obchodmi. V sledovanom testovaní dosiahol najlepšie reálne výsledky práve model EXTRATREES, ktorý vykazoval smerovú presnosť 57,41 % v tých vybraných 44,6 % dňoch, kedy bezpečne alokoval kapitál do trhu (čo zodpovedá 108 obchodným dňom z celkových 242). Pre porovnanie, referenčná pasívna stratégia držby (Buy & Hold) dosiahla v rovnakom časovom rámci úspešnosť denného rastu trhu iba v 53,2 % prípadov. Viaceré iné optimalizované algoritmy v simulácii logicky zaostávali, pričom pre niektoré nakoniec počet vykonaných obchodov klesol na nulovú úroveň (napríklad ELASTICNET alebo STACK). Stalo sa tak preto, lebo ich opatrné odhady nedokázali historicky generovať príkazy nad hranicou nami definovaného signálneho prahu.

4.4.2. Klasifikačná predikcia na nasledujúci deň



Obr. 3 Porovnanie predikcií klasifikačných modelov na nasledujúci deň

Obrázok č. 3 znázorňuje odhadované pravdepodobnosti rastu trhovej ceny na nasledujúci obchodný deň, vygenerované klasifikačnými modelmi. Graf na horizontálnej x-osi kvantifikuje

pravdepodobnosť, s akou daný model očakáva kladný denný výnos akcie. Hodnota 50 % je znázornená čiernou vertikálnou líniou a predstavuje absolútnu neutrálnu hranicu pohybu. Na grafickú aplikáciu konzervatívnejšieho obchodného pravidla sú tu fixne vyznačené ďalšie hraničné línie pre zóny vyššej štatistickej istoty - "Confident UP" pre pravdepodobnosť nad 55% a "Confident DOWN" pre pravdepodobnosť pod 45%. Horizontálne stĺpce reprezentujú výstupy jednotlivých klasifikátorov. Ich farba sa mení v závislosti od pásma, do ktorého spadá ich nameraná predikcia: zelená pre silný signál rastu, červená pre pravdepodobný pokles a oranžová pre oblasť trhovej neistoty. Tento modul slúži na doplnenie základných regresných odhadov o pravdepodobnostný kontext.

Rovnako ako pri regresnej analýze, aj v prípade klasifikácie je pre zhodnotenie schopností algoritmu nutné posúdiť dlhodobú historickú presnosť týchto pravdepodobnostných odhadov. Detailný súbor agregovaných klasifikačných metrík sumarizuje tabuľka na Obrázku č. 4 ktorá poskytuje porovnanie nielen pre štandardnú klasifikačnú úspešnosť Raw DA, ale uvádza aj metriky Mean Probability - priemerná historicky vygenerovaná pravdepodobnosť modelu a prenesenú hodnotu istoty Confident DA (> 55 %). Obchodný systém pri klasifikátoroch generuje nákupný signál iba vtedy, ak modelová pravdepodobnosť prekoná vopred stanovenú hranicu "veľkej istoty" 0,55.

Podľa nameraných dát dosiahol výsledky tímový meta-model STACK so smerovou presnosťou 54,7 % pri 35,5 % trhovom pokrytí (86 zrealizovaných obchodov z 242).

Model ^{↑↓}	Mean Probability ^{↑↓}	Raw DA ^{↑↓}	Confident DA (>55%) [↓]	Coverage ^{↑↓}	Trades ^{↑↓}
STACK (Clf)	53.36%	52.5%	54.7%	35.5%	86 / 242
LOGREG (Clf)	60.11%	51.7%	54.4%	80.6%	195 / 242
<i>Buy & Hold</i>	—	53.2%	53.2%	100.0%	
RF (Clf)	50.30%	47.5%	50.0%	51.2%	124 / 242
XGB (Clf)	52.45%	45.0%	42.9%	70.2%	170 / 242

Obr. 4 Classification Model Performance


Konkurenčný model LOGREG síce teoreticky pokryl až 80,6 % obchodných dní vďaka svojej vysokej priemernej hodnote pravdepodobnosti 60,11 %, avšak jeho konfidenčná úspešnosť 54,4 % mierne zaostala.

V porovnaní s referenčnou pasívnou stratégiou (Buy & Hold s dlhodobou úspešnosťou 53,2 %) dokázali tieto dva klasifikátory mierne navýšiť absolútnu matematickú pravdepodobnosť zisku z každého vykonaného obchodu. Samostatné stromové štruktúry RF a XGB v tomto

špecifickom meraní klasifikácie trh neprekonali, lebo ich smerová presnosť skončila pod úrovňou 50 %.

4.4.3. Analýza bodových odchýlok

Obrázok č. 5 znázorňuje bodový zhlukový graf, ktorý vizualizuje a sumarizuje priamy vzťah medzi predikovanými dennými logaritmickými výnosmi (zobrazenými na vertikálnej y-



Obr. 5 Predikované vs. Skutočné výnosy

osi) a skutočnými realizovanými trhovými výnosmi akcie Apple (na horizontálnej x-osi) počas testovacieho obdobia.

Každý jeden zobrazený bod v grafe reprezentuje uzatvorený denný odhad konkrétneho modelu pre jeden reálny obchodný deň. Uplatnené regresné algoritmy sú pre lepšiu prehľadnosť navzájom farebne odlišené. Tento grafický nástroj neslúži ani tak na meranie konečného zisku, ako skôr na vizuálnu diagnostiku chybovosti jednotlivých modelov.

Centrálnym analytickým a referenčným prvkom tohto grafu je prerušovaná diagonálna línia perfektnej predikcie. Ak by model dokázal v daný deň so stopercentnou presnosťou odhadnúť silu trhového pohybu, jeho nameraný bod by ležal presne na tejto priamke. V trhovej praxi však body nachádzajúce sa pod touto čiarou indikujú dni, kedy algoritmus reálny výnos matematicky podhodnotil, kým body nad touto čiarou znamenajú jeho faktické nadhodnotenie.

Z grafu je zrejmé, že predikcie modelov (na y-osi) sú oveľa menej rozptýlené ako skutočné denné výnosy trhu (na x-osi). Väčšina bodových predikcií sa nachádza v úzkom vodorovnom

páse blízko nuly, zatiaľ čo skutočné trhové výnosy vykazujú omnoho širšie rozpätie hodnôt, vrátane nepredvídateľných denných skokov. Znamená to, že algoritmy fungujú z historického hľadiska skôr konzervatívne - vo väčšine sledovaných dní predpovedajú iba relatívne malé, bežné trhové zmeny a systémovo sa nesnažia nerealisticky zachytávať extrémne cenové anomálie.


4.4.4. Distribúcia chýb predikcií

Obrázok č. 6 znázorňuje histogram hustoty rozdelenia predikčných pre všetky analyzované regresné modely. Táto trhová chyba je vo výpočtoch definovaná ako rozdiel medzi odhadovaným výnosom z výstupu modelu a skutočne realizovaným denným výnosom akcie.

Horizontálna os histogramu kvantifikuje priamu veľkosť spomínanej odchýlky, zatiaľ čo vertikálna os (Density) meria relatívnu frekvenciu výskytu konkrétnej chyby počas testovacieho obdobia. Čierna vertikálna línia na stredovej hodnote nula ($x = 0$) logicky reprezentuje scenár dokonalej trhovej predikcie s nulovou odchýlkou.

Z celkového tvaru zloženej distribúcie vyplýva, že chyby testovaných algoritmov sa formujú plne symetricky a ich výskyt sa koncentruje bezprostredne v okolí stredovej nulovej hodnoty. Skutočnosť, že ľavá aj pravá strana grafu klesajú relatívne rovnomerne naprieč modelmi, potvrdzuje kľúčový štatistický predpoklad: naše natrénované algoritmy netrpia takzvaným systematickým vychýlením. Modely teda budúce trhové výnosy ani permanentne

nepodhodnocujú, ani pravidelne nenadhodnocujú. Ich analytické nepresnosti iba prirodzene kopírujú každodennú trhovú volatilitu z oboch strán s neutrálnym rozptylom chýb.




Obr. 6 Prediction Error Distribution

4.4.5. Stabilita predikcií v čase

Obrázok č. 7 analyzuje časovú stabilitu predikčnej presnosti algoritmov. Zatiaľ čo predchádzajúce hodnotiace tabuľky vykazovali jeden konečný a statický priemer presnosti za celé doterajšie testovacie obdobie, tento čiarový graf dekonštruje metriku surovej smerovej presnosti (bez uplatnenia ziskového prahu) do plne dynamickej podoby.

Vertikálna os y kvantifikuje celkovú úspešnosť správneho odhadu modelu za systematického použitia metódy kĺzavého okna s dĺžkou 50 obchodných dní. Každý jeden zaznamenaný bod na spojitkej krivke tak v skutočnosti reprezentuje preukázanú priemernú presnosť modelu kumulatívne zmeranú výlučne počas posledných 50 zrealizovaných trhových pokusov pred daným dátumom.

Základným referenčným bodom grafu je čierna horizontálna prerušovaná línia fixovaná na úrovni 0,5. Tento prah štatisticky vizualizuje absolútnu hranicu náhodného odhadu. Hodnoty rastúce nad túto čiaru potvrdzujú reálnu pridanú informačnú hodnotu konkrétneho algoritmu, kým prepady pod ňu indikujú obdobie, v ktorom model generoval sériovo horšie odhady ako



Obr. 7 Vývoj klzavej smerovej presnosti modelov

hypotetické náhodné rozhodovanie. Pre hlbšie zasadenie do kontextu je do grafu integrovaná hrubá bodkovaná krivka, zosobňujúca referenčnú presnosť pasívneho prístupu držby akcií.

Z dlhodobého priebehu a vysokej volatility jednotlivých modelových kriviek vyplýva, že analytická schopnosť modelov správne predpovedať smer trhu nie je v čase prísne konštantná. Vo výpočtoch dochádza k evidentnému striedaniu fáz výkonnosti - napríklad primárne modely dokážu dočasne zachytávať výrazné presnosti ďaleko presahujúce úroveň 60%, avšak v obdobiach prudkých externých trhových zmien sa ich úspešnosť cyklicky vracia k náhodnému priemeru. Tento premenlivý priebeh empiricky dokazuje existenciu meniacich sa trhových mikroštruktúr a potvrdzuje náš predpoklad z predchádzajúcich tabuliek: aplikácia dodatočných obchodných prahov je na reálnom trhu striktné nevyhnutná, pretože žiadny algoritmus strojového učenia nedisponuje plnou imunitou voči limitovaným fázam vyššej dennej chybovosti.

4.4.6. Korelácia modelových signálov


Obrázok č. 8 slúži na porovnanie miery závislosti jednotlivých algoritmov. Prostredníctvom teplotnej mapy graficky vyhodnocuje vzájomnú lineárnu koreláciu vygenerovaných denných obchodných signálov medzi všetkými testovanými regresnými a klasifikačnými modelmi.

Farebná škála na pravej strane grafu vyjadruje číselnú silu korelácie. Hodnoty sa tu pohybujú od silne pozitívnej zhody - tmavočervená farba pre koreláciu blížiacu sa k hodnote 1

až po slabšiu či dokonca negatívnu koreláciu - modré odtiene s klesajúcimi hodnotami pod nulu. Hlavná diagonála matice prirodzene vykazuje maximálnu hodnotu 1, keďže vždy zobrazuje absolútnu zhodu modelu so sebou samým.

Vyššie prítomné hodnoty korelácie (tmavočervené oblasti) indikujú prítomnosť algoritmov, ktoré spracúvajú vstupné trhové dáta identicky a generujú veľmi podobné nákupné rozhodnutia. Zhluky vysokej pozitívnej korelácie sa podľa očakávania formujú prevažne medzi podobnými architektúrami na báze rozhodovacích stromov, čo potvrdzuje viditeľný blok zoskupujúci modely Random Forest či XGBoost.

Na účely diverzifikácie modelových prístupov v systéme je však dôležité identifikovať aj štvorce s nulovou alebo mierne negatívnou korelaciou (tmavomodré a svetlosivé oblasti). Tieto hodnoty preukazujú, že lineárne modely (napríklad REG_LINEAR či REG_SGD) generujú trhové signály omnoho nezávislejšie a na základe iného odhadu ako zložité stromové modely.




Obrázok č. 8: Korelačná matica generovaných obchodných signálov

V matici korelácie sa nachádzajú aj úplne prázdne riadky a stĺpce, patriace konkrétnym skupinám REG_ELASTICNET a REG_STACK. Nejde o chybu výpočtu; tento jav je priamym matematickým dôsledkom dát prezentovaných už v sumarizačnej tabuľke. Keďže tieto algoritmy nedokázali počas celého testovacieho obdobia vygenerovať ani jeden signál, ktorý by bezpečne prekročil obchodný prah (počet ich teoretických obchodov na trhu bol 0), ich rozptyl hodnôt signálov je nulový. Pre premennú, ktorá generuje iba statickú konštantu bez zmeny stavu, sa korelačný koeficient logicky nedá vypočítať, a preto pole v matici zostáva nevyplnené.

4.4.7. Výkonnosť, celkové výnosy stratégií a vývoj kapitálovej krivky

Obrázok č. 9 vizualizuje konečný dopad vygenerovaných modelových signálov na simulovanú finančnú výkonnosť stratégií. Graf zobrazuje vývoj relatívnej hodnoty investovaného kapitálu v priebehu celého sledovaného testovacieho obdobia. Počiatočný investovaný kapitál je pre účely porovnania vo všetkých sledovaných stratégiách nastavený na úroveň 1,0.




Obrázok č. 9: Vývoj kapitálovej krivky stratégií

Základným referenčným ukazovateľom je čierna spojitá línia, ktorá zastupuje výkonnosť pasívnej stratégie držby (Buy & Hold). Z priebehu na grafe je identifikovateľné, že táto pasívna metóda zaznamenala hneď v úvode testovacieho obdobia prepád kapitálu na úroveň pod 0,8, čo

predstavuje stratu viac ako 20 %, z ktorého sa akciový trh následne dlhodobo zotavoval. Na konci sledovaného obdobia dosiahla pasívna stratégia úroveň približne 1,099 (celkový výnos +9,94 %).

Jednotlivé farebné krivky na grafe reprezentujú aktívne obchodné stratégie riadené signálmi príslušných modelov strojového učenia. Horizontálne úseky na týchto krivkách priamo ukazujú uplatnenie podmienky HOLD / CASH z definovaných obchodných pravidiel. Plochý, nemenný stav na krivke totiž znamená, že daný model pre nasledujúci deň logaritmicným výnosom neprekonal požadovaný prah (+0,2 %) a systémový kapitál zostal z bezpečnostných dôvodov alokovaný v hotovosti. Práve táto vlastnosť stratégie umožnila najúspešnejším algoritmom efektívne ignorovať veľké trhové prepady. Príkladom je model REG_XGB, ktorého kapitálová krivka rástla počas ohraničených pozitívnych trendových epizód a dosiahla finálnu hodnotu nad 1,35 (kumulatívny výnos +35,74 %).

Vizuálne dáta z grafu zároveň korelujú so správaním nadmerne konzervatívnych modelov, akými boli napríklad REG_STACK či REG_ELASTICNET. Ich kapitálová krivka dopĺňa graf vo forme priamej, neprerušenej horizontálnej čiary na štartovacej hodnote 1,0. Tento bezvýnosový stav nadväzuje na skutočnosť, že tieto modely nezrealizovali žiaden obchod. Keďže penalizované lineárne algoritmy nedokázali počas roka vyprodukovať dostatočne silný predikčný signál prekračujúci prahovú hodnotu, nevystavili účet trhovému riziku a logicky tak nezaznamenali žiadnu finančnú stratu, no ani zisk.



Obr. 3 Obr. 10 Celkové výnosy stratégií modelov naviazaných na akciu AAPL.

Obrázok č. 10 stĺpcovou formou sumarizuje konečný kumulatívny výnos jednotlivých obchodných stratégií. Na rozdiel od kapitálových kriviek tento graf zhrňuje celú výkonnosť do jedného parametra, čo umožňuje jednoduchšie zhodnotenie finálneho výsledku každého modelu.

Najvyšší celkový výnos dosiahol regresný model REG_XGB, ktorý zhodnotil počiatočný kapitál o +35,74 % a výrazne prekonal ostatné prístupy. S väčším odstupom obsadili druhú a tretiu priečku modely REG_RF (+23,11 %) a REG_GBR (+20,06 %). Analýza ukazuje, že 7 z 12 testovaných modelov strojového učenia dokázalo prekonať benchmarkový výnos tradičnej stratégie Buy & Hold (+9,94 %). Prevažná časť úspešných modelov patrí do kategórie stromových regresných algoritmov, zatiaľ čo klasifikačné modely (s výnimkou CL_STACK a CL_LOGREG) väčšinou zaostávali.

Graf potvrdzuje aj prítomnosť stratových stratégií. Na opačnom konci výkonnostného spektra sa umiestnil model klasifikačného XGBoostu (CL_XGB). Napriek vysokej trhovej aktivite vygeneroval množstvo nepresných nákupných signálov, čo v konečnom dôsledku viedlo k poklesu kapitálu a celkovej strate -6,61 %. Tento výsledok podčiarkuje predpoklad, že vysoká frekvencia obchodov bez dostatočne presnej ochrany kapitálu pôsobí z dlhodobého hľadiska negatívne. Z tohto pohľadu preukázali regresné prístupy lepšiu schopnosť generovať stabilnejší výnos.


4.4.8. Mesačné výnosy

Obrázok č. 11 podrobnejšie rozkladá celkové výsledky stratégií a pomocou teplotnej mapy ukazuje výkonnosť jednotlivých modelov po mesiacoch. Zatiaľ čo predchádzajúce grafy hodnotili úspešnosť stratégií iba za celé obdobie, táto vizualizácia pomáha odhaliť, ako rovnomerne modely dosahovali svoje zisky a v ktorých fázach trhu fungovali najlepšie. Zelené tóny indikujú ziskové mesiace, kým oranžové a červené farby ohraničujú obdobia mesačných strát. Svetložltá farba a nuly označujú neutrálne mesiace, kedy model nezarobil, ale ani nestratil peniaze – napríklad preto, že pre nízku istotu nevstúpil do žiadneho obchodu.

Z pohľadu konzistencie vykazuje veľmi stabilné výsledky model REG_GBR. Aj keď celkovo neskončil prvý, väčšinu testovacích mesiacov dokázal uzavrieť v miernom pluse (zelenej farbe) a jeho straty v nepriaznivých obdobiach boli relatívne malé. Najziskovejší model REG_XGB, ktorý ovládol celkové štatistiky, taktiež ukazuje stabilný priebeh, no jeho úspech vo výraznej miere potiahli najmä dva extrémne silné mesiace v treťom štvrtroku 2025 (august

+11,61 % a september +8,14 %), kedy trh ponúkal jasné smerové príležitosti, ktoré tento model dokázal naplno využiť.

Naopak, klasifikačné modely vykazujú v teplotnej mape o niečo redšiu farebnú škálu, pričom sa pri nich častejšie striedajú výrazné straty so ziskami. Napríklad model CL_LOGREG zaknihoval veľmi úspešný august 2025 (s najvyšším mesačným zhodnotením celej mapy, +13,64 %), no hneď na to v iných mesiacoch čelil stratám (apríl a máj okolo -5 %). Obrázok opäť dopĺňajú modely REG_ELASTICNET a REG_STACK, ktorých celé stĺpce tvoria iba nuly. Keďže ani v jednom mesiaci neprekonali požadovaný predikčný prah na zadanie obchodu, ich zhodnotenie bolo po celý čas na nule. Tento mesačný prierez potvrdzuje, že aj najlepšie algoritmy




strojového učenia prechádzajú cyklami vyššej chybovosti a dokážu generovať výnos len vtedy, ak sa im podarí zosúladiť dostatočnú frekvenciu signálov s priaznivým rozdelením ziskových a stratových striedaní.

Obr. 11 Teplotná mapa mesačných výnosov modelov pre stratégiu AAPL.

4.4.9. Analýza dôležitosti vstupných premenných

Obrázok č. 12 poskytuje pohľad do vnútra rozhodovacieho procesu modelov. Graf zoradzuje dvadsať najužitočnejších vstupných premenných podľa ich priemernej dôležitosti, ktorá bola vypočítaná na základe výsledkov viacerých stromových algoritmov (ako napríklad Random Forest či XGBoost). Tento prístup pomáha pochopiť, z akých konkrétnych dát algoritmy najviac čerpali pri tvorbe svojich predikcií.



Obr. 4 Obr. 12 Priemerná dôležitosť TOP 20 atribútov naprieč stromovými modelmi.

Z výsledkov vyplýva, že najväčší vplyv na presnosť odhadu mali technické indikátory a historické cenové zmeny. Úplne najvyššiu dôležitosť dosiahol desaťdňový cenový moment (momentum_10), nasledovaný trojdňovým oneskorením logaritmických výnosov (log_ret_lag_3) a vypočítanou celkovou volatilitou trhu (volatility). Silné zastúpenie na popredných miestach majú aj ďalšie bežné technické ukazovatele, ako napríklad päťdňový jednoduchý kľzavý priemer (sma_5) či indikátory cci_20 a stoch_k. Opieranie sa o tieto

premenné naznačuje, že modely pre svoje denné predikcie primárne hľadajú krátkodobé cenové anomálie a lokálne trendy.

Okrem samotnej akcie Apple sa algoritmy vo veľkej miere spoliehali na vývoj celého technologického sektora. Potvrďuje to vysoká pozícia premennej `qqq_change_lag_3` (výnos indexu Nasdaq 100 s posunom troch dní). Tento fakt dáva zmysel, keďže pohyby akcií Apple sú dlhodobo silne previazané s celkovým náladami na technologickom trhu.

Veľmi zaujímavým zistením je prítomnosť alternatívnych dát v rebríčku najlepšej dvadsiatky. Dáta získané z internetového vyhľadávania (ako kľúčové slová `ai_search_lag_3` alebo `election_search`) a frekvencia spravodajských článkov o clách (`tariffs_news`) preukázali užitočnosť pri predikciách. Hoci ich relatívna váha nie je až taká veľká ako pri priamych technických a cenových indikátoroch, ich prítomnosť v grafe potvrdzuje náš predpoklad z teoretickej časti práce: makroekonomické udalosti, politika a záujem verejnosti reálne pomáhajú algoritmom spresniť odhad budúceho vývoja akcie.


4.4.10. Rozloženie dôležitosti atribútov podľa jednotlivých modelov

Obrázok č. 13 rozširuje predchádzajúci pohľad a detailne ukazuje, ako k desiatim celkovo najužitočnejším premenným pristupovali rôzne stromové algoritmy (Random Forest, XGBoost, Gradient Boosting a Extra Trees v regresnej aj klasifikačnej podobe). Kým predchádzajúci graf spriemeroval hodnoty do jedného celku, tento skupinový stĺpcový graf odhaľuje rozdiely vo vnútornej logike a rozhodovaní jednotlivých modelov.

Z rozloženia stĺpcov vyplýva, že modely nevyužívajú trhové dáta rovnako. Výrazným príkladom je model Gradient Boosting (GBR, znázornený ružovou farbou), ktorý pripisuje extrémnu váhu premennej `log_ret_lag_3` (s hodnotou blížiacou sa k hranici 0,175). Pre tento algoritmus ide o bezkonkurenčne najdôležitejší indikátor, od ktorého odvodzuje väčšinu svojich odhadov. Naopak, model Extra Trees (svetlozelený stĺpec) sa zo všetkých najviac spolieha na `momentum_10`, kde jeho váha presahuje 0,15 a dominuje nad ostatnými prístupmi.

Zaujímavé je aj správanie modelov z rodiny XGBoost (regresný XGB – oranžový stĺpec a klasifikačný CL_XGB – sivý stĺpec). Hodnoty týchto modelov sú naprieč všetkými zobrazenými atribútmi relatívne vyrovnané a málokedy vytvárajú výrazné extrémny. To ukazuje, že XGBoost sa pri rozhodovaní nespolieha primárne na jeden alebo dva hlavné faktory, ale svoju pozornosť a výpočty rozkladá oveľa rovnomernejšie medzi širšie spektrum premenných. Rovnako rovnomerne modely pristupujú aj k alternatívnym dátam z vyhľadávania

(ai_search_lag_3 a election_search), kde sa ich váhy pohybujú v stabilnom pásme okolo hodnoty 0,05 až 0,07.



Obr. 5Obr. 13 Dôležitosť TOP 10 atribútov v rozklade na konkrétne stromové modely.

Táto rôznorodosť v prístupe k dátam zároveň vysvetľuje, prečo priradujú rôzne algoritmy v rovnaký deň odlišný trhovú signál. Každý model si v identickom datasete nachádza iné vnútorné matematické vzťahy, čo v konečnom dôsledku spôsobuje rozdiely v ich celkovej ziskovosti prezentovanej v predošlých grafoch.

4.4.11. Lineárna korelácia atribútov s cieľovou premennou

Obrázok č. 14 poskytuje analytický pohľad na priamy lineárny vzťah medzi najužitočnejšími atribútmi (identifikovanými v predchádzajúcich modeloch) a cieľovou premennou, ktorou je logaritmický výnos ceny akcií v nasledujúci obchodný deň (next-day log_ret). Zelené stĺpce smerujúce doprava ukazujú pozitívnu koreláciu, zatiaľ čo červené stĺpce smerujúce doľava reprezentujú negatívnu koreláciu. Hodnota korelačného koeficientu opisuje silu a smer tohto vzťahu.

Z grafu je okamžite viditeľné, že najsilnejšiu priamu závislosť vykazujú alternatívne dáta z prostredia Google vyhľadávania a spravodajstva. Zvýšený záujem reprezentovaný dotazom `election_search` vykazuje zo všetkých premenných najsilnejšiu pozitívnu koreláciu (približne 0,04). Tento výsledok naznačuje prítomnosť psychologického efektu, kde vyšší verejný záujem o kľúčové makro-témy môže predchádzať krátkodobému nárastu ceny akcií Apple. Do rovnakej kategórie môžeme zaradiť a premenné pre správy o clách (`tariffs_news_lag_1` a `tariffs_news_lag_3`), ktorých pozitívny lineárny vplyv presahuje úroveň 0,02.




Obr. 6 Obr. 14 Pearsonova korelácia TOP 20 najdôležitejších atribútov s výnosom nasledujúceho dňa pre AAPL.

Opačný efekt preukazujú tradičné technické indikátory a historické metriky ceny. Extrémne cenové rozvírenie (`volatility`), kľzavý priemer ceny (`sma_5`) a index krátkodobého hybnosti (`momentum_10`) spoločne dosahujú takmer symetrickú negatívnu koreláciu blízko úrovne -0,04. To znamená, že nadpriemerne silný rast týchto indikátorov historicky v datasetoch viedol k poklesu reálneho výnosu na nasledujúci deň, čo pravdepodobne svedčí o výskyte krátkodobých výpredajov po prudkom cenovom náraste spôsobenom napríklad silným momentom a vyššou volatilitou trhu.

Rovnakým spôsobom interpretujeme aj inverzný vplyv historických výnosov a spravodajstva. Predchádzajúci trojdňový pokles cien (`log_ret_lag_3`) a dvojdnové trvanie negatívnych správ o výsledkoch spoločnosti (`earnings_news_lag_2`) paradoxne signalizujú krátkodobý prírastok, kedy algoritmy zachytávajú náchylnosť trhu krapídnejšiemu zotavovaniu z negatívnych udalostí.

Na tento fakt je potrebné pristupovať opatrne, keďže všetky tieto zistené lineárne vzťahy dosahujú z matematického hľadiska iba nízke korelačné hodnoty (v absolútnom vyjadrení do územia 0,05). To znamená, že žiadna z premenných sama o sebe nedokáže spoľahlivo a univerzálne určiť výnos na ďalší deň. Celé zmysluplné jadro modelov strojového učenia, ktoré sme predstavili v predchádzajúcich kapitolách, teda spočíva práve vo výkyvoch a nelineárnom spájaní týchto malých korelujúcich prvkov do komplexného predikčného vzorca, v ktorom si navzájom prispôsobujú váhu podľa meniacich sa fáz trhového mikroštruktúr akciového trhu.



Obr. 7 Obr. 15 Celkový vplyv jednotlivých skupín atribútov na predikcie modelov pre AAPL.

4.4.12. Agregovaná dôležitosť podľa kategórií dát

Obrázok č. 15 zoskupuje všetky použité vstupné premenné do logických kategórií a ukazuje ich celkovú sčítanú dôležitosť pri rozhodovaní algoritmov. Kým predchádzajúce grafy

sa zameriavali na individuálne premenné, tento stĺpcový graf zodpovedá na širšiu otázku: Aký typ trhových informácií predstavoval pre modely najväčšiu pridanú hodnotu?

Celkom dominantnú pozíciu si udržali technické indikátory (žltý stĺpec, s celkovou váhou presahujúcou úroveň 0,35). Do tejto skupiny patria matematické ukazovatele ako kľzavé priemery (SMA), RSI, MACD či Bollingerove pásma. Výsledok potvrdzuje, že algoritmy dokážu priamo nadviazať na princípy klasickej technickej analýzy a vo veľkej miere ju využívajú na odhadovanie krátkodobých výkyvov cien.

Na druhom mieste skončili historické cenové oneskorenia - takzvané Return Lags (zelený stĺpec, váha takmer 0,20). Samotné čisté dáta o tom, ako sa cena správala pred jedným, tromi alebo dvadsiatimi dňami, poskytovali modelom základný zachytý bod pri určovaní základného trhového trendu (momenta) či snahy trhu korigovať predošlé prepady.

Významným zistením, ktoré potvrdzuje hlavnú hypotézu o pridanej hodnote alternatívnych dát z teoretickej časti, je umiestnenie sekcií spravodajských (News Trends) a vyhľadávacích trendov (Search Trends). Aj keď tieto dve sady dát pochádzajú mimo tradičného obchodného prostredia, po agregovaní vyčíslili spoločný informačný vplyv porovnateľný, respektíve zľahka prevyšujúci úroveň štatistických a celotrhových kategórií (ako VIX a QQQ). Modely teda preukázateľne využívajú frekvenciu kľúčových vyhľadávacích pojmov (napr. ohľadom iPhone, umelej inteligencie či volieb) na doplnenie kontextu, ktorý bežné technické indikátory jednoducho nedokážu zachytiť.

Najmenšiu celkovú váhu zaznamenali štatistické momenty trhu (šikmost', špicatosť) a celotrhové indikátory (modrý stĺpec Market). To ukazuje, že po spracovaní špecifických indikátorov pre akciu Apple modelom už chýba silný dodatočný prínos zo stavu širšieho trhu, resp. tento vplyv zachytávajú inými cestami.


Celková distribúcia jednoznačne svedčí o tom, že strojové učenie na finančných trhoch nefunguje reduktívne iba na základe jednej triedy dát, ale skladá úspešnú predikciu kombinovaním tradičnej kvantitatívnej analýzy s moderným meraním sentimentu.

4.4.13. Interpretácia modelu prostredníctvom SHAP hodnôt

Obrázok č. 16 predstavuje detailný pohľad do "čiernej skrinky" algoritmu pomocou metódy SHAP (SHapley Additive exPlanations). Tento Bee Swarm graf neradí atribúty len podľa ich priemernej dôležitosti (na vertikálnej osi zhora nadol), ale predovšetkým vizualizuje, ako presne konkrétne hodnoty týchto premenných menia výslednú predikciu modelu u každého

jedného dátového bodu (na horizontálnej osi). Farba bodky reprezentuje samotnú hodnotu premennej - od modrej pre nízke hodnoty až po červenú pre vysoké.

Najväčšiu pozornosť strháva hneď prvý atribút, ktorým je celková volatilita trhu (volatility). Tu vidíme silný zhuk červených bodiek smerujúcich výrazne doľava, do záporných SHAP hodnôt. To znamená, že keď bola volatilita na trhu vysoká (červená farba), model mal silnú tendenciu znižovať svoj odhad nasledujúceho výnosu a očakával skôr prepád. Naopak, nízka až priemerná volatilita (modré a fialové body) mierne pozitívne posúvala predikciu smerom doprava.



Obr. 8 SHAP Summary plot (Bee Swarm) pre najplyvnejšie premenné na datasete AAPL

Podobne sa správa krátkodobé cenové hybnosti, reprezentované premennou momentum_10. Tu zhuk modrých bodov (nízke momentum, teda počiatočný prepád ceny) smeruje doprava do mierne kladných hodnôt SHAP, čo indikuje očakávanie odrazu ceny smerom

nahor. Pre extrémne vysoké momentum graf však ukazuje rozptýlené vzorce, kedy model nepredpokladá jednoznačný smer a vyhodnocuje ho v kontexte ostatných premenných.

Graf takisto potvrdzuje a rozširuje zistenia z korelačnej analýzy pri makroekonomických a alternatívnych indikátoroch. Vidíme, že výrazný pokles širšieho indexu (snp500_change s modrými bodmi vľavo) mal tendenciu stiahnuť nižšie aj predikciu pre Apple. Naopak, vysoké hodnoty vo vyhľadávaní volieb (election_search s červenými bodmi posunutými doprava) mali na výstup pozitívny vplyv a zvyšovali predikovaný výnos.

Rozptýlenie bodiek na obidve strany stredovej čiary pri takmer všetkých premenných je najlepším dôkazom nelinearity prístupu strojového učenia. Graf jasne demonštruje, že model nevyužíva prosté lineárne pravidlá ("ak stúpne X, klesne Y"), ale že vplyv vysokej alebo nízkej hodnoty premennej silne závisí od interakcie so zvyškom indikátorov v danom konkrétnom trhovom dni.

4.4.14. Globálna dôležitosť parametrov pomocou SHAP hodnôt


Obrázok č. 17 dopĺňa predchádzajúci detailný bodový graf a sumarizuje celkový globálny vplyv jednotlivých premenných na predikcie modelu. Graf zoradí atribúty na základe ich priemernej absolútnej SHAP hodnoty. Na rozdiel od tradičných metód výpočtu dôležitosti pri náhodných lesoch (postavených na poklese entropie), priemerná absolútna hodnota SHAP presne kvantifikuje, o koľko daná premenná v priemere zmenila (zvýšila alebo znížila) predikciu logaritmického výnosu v absolútnom čísle.

Výsledky jednoznačne potvrdzujú dominanciu premennej opisujúcej volatilitu (volatility). Jej stĺpec je najdlhší a prekonáva všetky ostatné atribúty. Znamená to, že miera denného cenového rozpätia a celkovej „nervozity“ na trhu mala najväčšiu silu modifikovať konečné rozhodnutie algoritmov pri odhade budúcich krokov spoločnosti Apple.

Hneď za volatilitou nasleduje trojica úzko spätá s minulým obchodovaním predmetnej akcie - zobchodovaný objem z predchádzajúceho dňa (volume_lag_1), krátkodobý 5-dňový kľzavý priemer ceny (sma_5) a cenové momentum (momentum_10). Tieto klasické technické atribúty poskytovali modelu nevyhnutný kontext o vývoji lokálneho trendu.

Z hľadiska makroprostredia je cenným analytickým objavom vysoká pozícia širších trhových ukazovateľov. Historické zmeny indexov S&P 500 (snp500_change) a Nasdaq (qqq_change_lag_3) sa umiestnili ihneď za primárnymi technickými nástrojmi v prvej šiestici najvplyvnejších faktorov. Model vyhodnotil silnú previazanosť výkonnosti akcie stelesňujúcej

vrchol technologického trhu so širšími investičnými náladami. Do hornej polovice sa prebojoval aj parameter `election_search`, čo opätovne dokazuje, že pridaním netradičných dát o dopytoch vo vyhľadávачoch algoritmus získal platnú informačnú výhodu.



Obr. 9 Obr. 17 Priemerná absolútna hodnota SHAP (Globálna dôležitosť) pre AAPL.

4.4.15. Čiastkové zhrnutie výsledkov pre akciu Apple

Komplexná analýza akcie spoločnosti Apple potvrdila, že modely strojového učenia dokážu na finančných trhoch priniesť merateľnú informačnú výhodu, ak sú správne nastavené a chránené vhodnými pravidlami riadenia rizika.

Z hľadiska výkonnosti sa ako najperspektívnejšie ukázali regresné stromové algoritmy, predovšetkým model Gradient Boosting a XGBoost. Najúspešnejší model (REG_XGB) dokázal v testovacom období zhodnotiť počiatočný kapitál o 35,74 %, čím úspešne prekonal pasívnu stratégiu držby (Buy & Hold), ktorá dosiahla zisk necelých 10 %. Tieto nadpriemerné výsledky však neboli dosiahnuté bezhlavým obchodovaním každý deň. Kľúčovú úlohu zohral filter v podobe signálneho prahu (+0,2 %). Modely vstupovali do dlhej pozície iba vtedy, keď bola ich matematická istota dostatočne vysoká. V obdobiach trhovej neistoty tak účet ostával chránený v hotovosti, čo algoritmom umožnilo vyhnúť sa najväčším trhovým prepadom.

Pohľad do vnútra rozhodovacej logiky modelov, cez dôležitosť atribútov a SHAP analýzu, ukázal, že strojové učenie nekladie váhu iba na jeden konkrétny parameter. Najväčší vplyv na predikcie síce mali tradičné trhové metriky ako denná volatilita, cenové momentum a kľzavé priemery (SMA), no algoritmy ich nelineárne prepájali so širším trhovým kontextom ako su vývoj indexov S&P 500 a Nasdaq.

Z pohľadu cieľov tejto práce je najdôležitejším zistením preukázaný prínos alternatívnych dát. Metriky z internetového vyhľadávania a analýza spravodajských titulkov (napríklad vyhľadávanie okolo iphone alebo volieb či správy o clách) sa stabilne umiestňovali v prvej dvadsiatke najdôležitejších atribútov naprieč viacerými modelmi. Potvrdili sme tak teoretický predpoklad, že verejný záujem a makroekonomické udalosti nesú informáciu, ktorú klasická technická analýza nevidí, a modely strojového učenia ju dokážu reálne zúročiť pri odhade vývoja ceny v nasledujúci deň.

4.5. Popisanie výsledkov

Podobne aj pre ine spoločnosti a sú v prílohe

Popis 30 spoločností + index

5. Zaver

Bez cisel

Zoznam použitej literatúry

- Andrika, M. Y., & Rahardi, M. (2025). Comparative Study of Linear Regression, SVR, and XGBoost for
- Agarwal, R. (2024). Financial Performance Prediction and Stability Analysis Using SHAP-Enhanced Machine Learning Models.
- Andrika, M. Y., & Rahardi, M. (2025). Comparative Study of Linear Regression, SVR, and XGBoost for Stock Price Prediction After a Stock Split. *Journal of Applied Informatics and Computing*.
- Cibuľa, M. (2022). Strojové učenie ako srdce umelej inteligencie pre investora. *Finančné trhy*, 1.
- Deep, A., Monico, C., Shirvani, A., Rachev, S., & Fabozzi, F. J. (2024). Assessing the Impact of Technical Indicators on Machine Learning Models for Stock Price Prediction.
- Deswal, V. (2023). Stock Price Prediction of AAPL Stock by Using Machine Learning Techniques: A Comparative Study. *12th International Conference on System Modeling & Advancement in Research Trends*.
- Jin, X., & Yi, C. (2023). Stock price prediction using multiple machine learning algorithms. *ICBBEM*.
- Kim, H., Cho, H., & Ryu, D. (2020). Corporate Default Predictions Using Machine Learning: Literature Review. *Sustainability*, 12(16), 6325.
- Kristanti, F. T., Febrianta, M. Y., Salim, D. F., Riyadh, H. A., Sagama, Y., & Beshr, B. A. H. (2024). Financial distress prediction using ensemble machine learning models. *Journal of Infrastructure, Policy and Development*.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.
- MDPI. (2020). Predicting Financial Distress of Slovak Enterprises: Comparison of Selected Traditional and Learning Algorithms Methods. *Sustainability*.
- MDPI. (2024). Modeling and Forecasting the Morocco Stock Index 20 Using Machine Learning Methods. *Forecasting*, 7(1), 39.

Nageswaran, M. K., & Sankarasubramanian, R. (2026). Simple Stock Price Prediction Using Machine Learning. *The Bioscan*, 21(1), 393-401.

Panggabean, & Widyasari. (2023). Performance Comparison of Random Forest Regression, SVR Models in Stock Price Prediction. *Jurnal Pilar Nusa Mandiri*.

Raya, a kol. (2022). Stock price prediction utilizing machine learning algorithms.

Shi, H. (2024). Tesla Stock Price Forecast Based on ARIMA Model and Machine Learning Techniques.

Wang, H. (2023). Stock Price Prediction Based on Machine Learning. Atlantis Press.

Wang, H. (2025). Stock Return Prediction Based on Linear Regression, Random Forest and XGBoost. Atlantis Press.

Zhao, Y. (2025). Research on Interpretable Machine Learning Models for Identifying Corporate Bond Default Risk. *Population, Resources & Environmental Economics*, 6, 38-45.

Zubair, M., a kol. (2024). Machine Learning Insights into Retail Sales Prediction: A Comparative Analysis of Algorithms.

Prílohy