

**EKONOMICKÁ UNIVERZITA V BRATISLAVE
NÁZOV FAKULTY**

Evidenčné číslo:

**VYUŽITIE NÁSTROJOV STROJOVÉHO UČENIA VO
FINANČNEJ ANALÝZE**

Diplomová práca

EKONOMICKÁ UNIVERZITA V BRATISLAVE
NÁZOV FAKULTY

VYUŽITIE NÁSTROJOV STROJOVÉHO UČENIA VO
FINANČNEJ ANALÝZE

Diplomová práca

Študijný program: Data science v ekonómii
Študijný odbor: Ekonómia a manažment
Školiace pracovisko: Katedra operačného výskumu a ekonometrie
Vedúci záverečnej práce: prof. Mgr. Juraj Pekár, PhD.

Bratislava 2026

Bc. Luka Kuzyk

ABSTRAKT

PRIEZVISKO, Meno: *Názov záverečnej práce.* – Ekonomická univerzita v Bratislave. Názov fakulty; názov katedry. – Vedúci/vedúca záverečnej práce (pri dizertačných prácach školiteľ/školiteľka): tituly pred menom, meno a priezvisko, tituly za menom. – Bratislava: skratka fakulty (napr. NHF EU), rok, počet strán (napr. 70 s.)

Záverečná (habilitačnej) práce je vypracovaná na tému Cieľom záverečnej práce bolo

.....

..... Jednotlivé časti záverečnej práce boli zamerané na

.....

Výsledkom riešenia danej problematiky je

.....

Kľúčové

slová:

.....

ABSTRACT

Znenie slovenského abstraktu uviesť aj v anglickom, prípadne inom cudzom jazyku vrátane identifikačných údajov na začiatku abstraktu.

O B S A H

ÚVOD.....	5
1. ANALÝZA SÚČASNÉHO STAVU 4 STRANY A HLAVNE LITERATURA	6
1.1. FINANČNÁ ANALÝZA PROSTREDNÍCTVOM STROJOVÉHO UČENIA	6
1.2. APLIKÁCIA A POROVNANIE ML MODELOV PRI PREDIKCII CIEN AKCIÍ	6
1.2.1. <i>Lineárne modely a stromové algoritmy.....</i>	<i>7</i>
1.2.2. <i>Ansámblové metódy a metóda podporných vektorov</i>	<i>8</i>
1.2.3. <i>Predikcia finančnej tiesne a bankrotu ako klasifikačná úloha.....</i>	<i>9</i>
1.3. INTERPRETOVATELNOSŤ MODELOV STROJOVÉHO UČENIA VO FINANCIÁCH	10
1.4. VPLYV TECHNICKÝCH INDIKÁTOROV A DÁTOVÉHO ŠUMU NA PRESNOSŤ.....	10
2. CIEL PRACE A METODIKA	12
3. METODY A NÁVRH PREDIKČNÉHO FRAMEWORKU DO 10 STRAN.....	13
3.1 VÝSKUMNÉ CIELE A FORMULÁCIA PROBLÉMU	13
3.2 ARCHITEKTÚRA SYSTÉMU A DÁTOVÝ TOK.....	13
3.3 ZBER DÁT A VÝBER AKTÍV	13
3.4 HODNOTIACE METRIKY	15
4. IMPLEMENTÁCIA STROJOVÉHO UČENIA.....	16
4.1 DÁTOVÁ ZAKLADNA	16
PREDSPRACOVANIE	16
4.2 SPOSOBY AKO SA TO ROBILO.....	16
4.3 POPISANIE VYSLEDKOV.....	16
5.	17
6. ZÁVER.....	18
ZOZNAM POUŽITEJ LITERATÚRY.....	20
PRÍLOHY.....	22

Úvod

1. Analýza súčasného stavu 4 strany a hlavne literatúra

Súčasný globálny finančný trh sú charakteristické vysokou volatilitou, nelinearitou a stochastickým správaním, čo z predikcie cien finančných aktív robí jednu z najzložitejších analytických úloh. Táto kapitola analyzuje aktuálny stav vedeckého poznania v oblasti aplikácie algoritmov strojového učenia (Machine Learning - ML) vo finančnej analýze, so špecifickým zameraním na komparatívne štúdie modelov využívaných na predikciu cien akcií.

1.1. Finančná analýza prostredníctvom strojového učenia

Integrácia algoritmov strojového učenia (Machine Learning – ML) do oblasti finančnej analytiky predstavuje jednu z najdôležitejších etáp vývoja súčasnej kvantitatívnej ekonómie. Po desaťročia zostávala fundamentálnym základom finančnej teórie Hypotéza efektívneho trhu (Efficient Market Hypothesis – EMH), ktorá predpokladá, že všetky dostupné informačné toky sa okamžite a úplne premietajú do cien finančných aktív. Podľa tejto teórie sa budúce cenové pohyby riadia princípom „náhodnej prechádzky“ (random walk), čo robí systematické predpovedanie trhu nemožným (López de Prado, 2018).

Pred príchodom pokročilých techník strojového učenia sa investori a analytici pri analýze časových radov cien akcií spoliehali dominantne na tradičné štatistické a ekonometrické modely, akými sú napríklad modely ARIMA (Auto-Regressive Integrated Moving Average) alebo GARCH (Cibuľa, 2022). Hoci sú tieto modely vysoko efektívne v stabilnom prostredí a poskytujú dobrú štatistickú interpretovateľnosť, ich fundamentálnym obmedzením je predpoklad linearity a stacionarity dát (Shi, 2024). Na reálnych trhoch plných štrukturálnych šokov však tieto predpoklady často zlyhávajú.

Obrovský skok vo výkone počítačov a dostupnosť historických trhových dát spôsobili, že za posledné desaťročie sa do popredia dostalo strojové učenie. Výhoda týchto algoritmov je, že sa dokážu učiť z historických dát sami a dokážu zachytiť aj dynamické, zložité a nelineárne zmeny na trhu bez toho, aby sme ich museli na to zložito programovať (Cibuľa, 2022). V súčasnosti sa vedecký výskum zameriava hlavne na porovnávanie klasických prístupov so stromovými modelmi, napríklad Random Forest a XGBoost, a architektúrami neurónových sietí prispôbovaných na časové rady, najmä LSTM (Jin & Yi, 2023).

1.2. Aplikácia a porovnanie ML modelov pri predikcii cien akcií

Z analýzy nedávnych štúdií vyplýva, že autori vo svojich výskumoch spravidla hľadajú optimálnu rovnováhu medzi presnosťou predikcie – vyhodnocovanou najčastejšie pomocou

metriek ako stredná kvadratická chyba (MSE), odmocnina strednej kvadratickej chyby (RMSE) a stredná absolútna chyba (MAE) – a výpočtovou efektivitou daného modelu. V odbornej literatúre sa na predikciu cien akcií najčastejšie využíva komparácia lineárnych modelov, modelov založených na metóde podporných vektorov (SVR) a ansámblových stromových techník.

1.2.1. Lineárne modely a stromové algoritmy

Deswal vo svojom výskume porovnával modely lineárnej regresie a algoritmu Random Forest (RF) pri predikcii zatváracích cien akcií technologickej spoločnosti Apple. Z výsledkov jeho experimentu vyplynulo, že na konkrétnom súbore dát bez prítomnosti extrémneho trhového šumu preukázal model klasickej lineárnej regresie lepšiu schopnosť prispôbiť sa cenovému trendu. Autor dospel k záveru, že lineárna regresia dosiahla v tomto špecifickom prípade nižšie hodnoty chýb MSE a RMSE a na stabilných úsekoch vykazovala rýchlejšiu odozvu na cenové zmeny ako Random Forest (Deswal, 2023).

K podobným záverom dospeli aj Andrika a Rahardi, ktorí vo svojej štúdii zameranej na predikciu akcií po ich rozdelení zistili, že pri jasne definovaných stabilných trendoch môžu byť jednoduchšie regresné prístupy adekvátne presné a predovšetkým výpočtovo nenáročné v porovnaní s komplexnými algoritmi (Andrika & Rahardi, 2025). Tento fenomén detailne skúmal aj Wang, ktorý zbieral a analyzoval dáta šiestich technologických gigantov (tzv. skupiny FAANG+M) na burze NASDAQ v rokoch 2015 až 2024 a testoval modely lineárnej regresie, Random Forest a XGBoost s cieľom eliminovať trhové fluktuácie. Výsledky jeho výskumu ukázali, že v tomto špecifickom kontexte dosahovala lineárna regresia optimálne výsledky, zatiaľ čo zložitejšie modely zaostávali. Autor tento výsledok vysvetľuje existenciou pozitívnej korelácie medzi jednoduchosťou modelu a kvalitou výsledku v stabilnom prostredí, pričom upozorňuje, že zložitosť stromových modelov často vedie k nechcenému problému s preučeníím na historických dátach (Wang, 2025).

Ďalšia porovnávacia štúdia (Zubair a kol., 2024) potvrdila, že komplexný rozbor výkonnostných metrík je absolútne nevyhnutný pre správny výber modelu, pričom voľba medzi lineárnou regresiou, Random Forest a XGBoost by mala vždy zohľadňovať predovšetkým mieru nelinearity samotných dát. Na domácich dátach tento prístup overovala štúdia publikovaná v MDPI (2020), ktorá podrobne analyzovala výkonnosť modelov na rozsiahlom súbore dát slovenských priemyselných podnikov. Autori postavili do priameho kontrastu klasickú logistickú regresiu proti učiacim sa algoritmom, reprezentovaným najmä modelom Random Forest. Z výsledkov výskumu vyplynulo, že algoritmy strojového učenia prekonal tradičnú regresnú analýzu vo viacerých metrikách vrátane celkovej presnosti a parametrov LogLoss, čo

dokumentuje ich schopnosť lepšie pracovať s komplexnými a nelineárnymi finančnými dátami (MDPI, 2020).

1.2.2. Ansámblové metódy a metóda podporných vektorov

Pre trhy a akcie s vyššou mierou volatility sa však do popredia jednoznačne dostávajú ansámblové techniky. Tieto modely, reprezentované najmä algoritmami Random Forest (RF) a eXtreme Gradient Boosting (XGBoost), fungujú na princípe agregácie viacerých slabších rozhodovacích stromov (prediktorov) do jedného robustného celku. Vo svojej štúdii Jin a Yi analyzovali vplyv technických indikátorov a zdôraznili, že agregované metódy vďaka zabudovaným mechanizmom odolnosti voči preučeniu výrazne prekonávajú samostatné rozhodovacie stromy (Jin & Yi, 2023).

Súperenie dvoch najrozšírenejších ansámblových prístupov bolo predmetom štúdií Panggabean a Widyasari kde autori realizovali výskum zameraný na porovnanie modelu Random Forest a Support Vector Regression (SVR). Zistili, že Random Forest dosiahol pri predikcii mimoriadne vysokú presnosť (R^2 skóre na úrovni 0.997) a preukázal sa ako oveľa robustnejší nástroj pri analýze trhových dát v nestabilných podmienkach v porovnaní s modelom SVR, ktorý vykazoval vyššiu mieru chybovosti meraní cez MAE a RMSE (Panggabean & Widyasari, 2023). Podobné výsledky zaznamenali aj Raya a kol. (2022), ktorí na základe hodnotenia metriky MAE skonštatovali, že spomedzi testovaných algoritmov, vrátane SVR a klasických prístupov, preukázal práve Random Forest najlepšie predikčné schopnosti.

Na druhej strane, iná empirická štúdia (MDPI, 2024), ktorá modelovala a predpovedala denné ceny akciového indexu MSI 20, priniesla odlišnú perspektívu. Autori v nej testovali SVR aj XGBoost, pričom pri ladení hyperparametrov využili techniku Grid Search. Výsledky preukázali, že po dôkladnej optimalizácii parametrov dokázal model SVR dosiahnuť vynikajúcu predikčnú presnosť a v niektorých prípadoch dokonca prekonať iné, bežne využívané ansámblové algoritmy.

Ďalšie porovnanie prináša vo svojej práci Wang, ktorý aplikoval široké spektrum metód strojového učenia, vrátane lineárnej regresie, SVR, K-Nearest Neighbors (KNN) a ansámblových metód Bagging, AdaBoost, XGBoost na akcie spoločností z rôznych sektorov, konkrétne Intel, Coca-Cola a Exxon Mobil. Z jeho analýzy vyplýva zistenie, že neexistuje jeden univerzálny predikčný model. Kým pre technologický sektor s nelineárnymi výkyvmi vykazovali najvyššiu presnosť metódy Bagging a XGBoost, pre iné sektory s odlišnou dynamikou cien, ako je potravinársky priemysel, sa úspešne uplatnili aj odlišné algoritmy. Uvedená štúdia zároveň

podčiarkuje dôležitosť správneho ladenia hyperparametrov a selekcie vstupných premenných, ktoré sú kritické pre maximalizáciu výkonu akéhokoľvek ML modelu (Wang, 2023).

1.2.3. Predikcia finančnej tiesne a bankrotu ako klasifikačná úloha

Okrem predikcie samotných cien akcií sa metódy klasického strojového učenia vo finančnej analýze intenzívne porovnávajú aj v klasifikačných úlohách, akými je napríklad predikcia finančnej tiesne podnikov. Tento smer analýzy bezprostredne súvisí s vývojom fundamentálnej hodnoty akcií podniku. Kim a kol. (2020) vo svojej prehľadovej štúdii definujú, že popri štatistických modeloch tvoria jadro moderných varovných systémov práve klasifikátory podporných vektorov (SVM) a rozhodovacie stromy. Autori tiež zdôrazňujú, že úspešný model strojového učenia pre predikciu bankrotu musí byť schopný jasne indikovať hlavnú príčinu zlyhania.

V rozsiahlej porovnávacej štúdii Kristanti a kol. (2024) testovali schopnosť modelov predpovedať úpadok na základe účtovných a finančných pomerových ukazovateľov u spoločností na indonézskej burze cenných papierov. Autori skúšali modely SVM, KNN, Random Forest a XGBoost. Vzhľadom na to, že finančné dáta o bankrotoch bývajú výrazne skreslené v prospech určitej triedy, implementovali techniku prevzorkovania SMOTE. Výsledky tohto výskumu jasne potvrdili dominanciu stromových ansámblových metód. Klasifikátory XGBoost a Random Forest dosiahli po aplikácii vyvažovacej techniky presnosť presahujúcu 96 %, čím výrazne prekonal modely založené na vzdialenosti (KNN) a vektoroch (SVM) v schopnosti spoľahlivo identifikovať anomálie v účtovných výkazoch (Kristanti a kol., 2024).

Podobne úspešné nasadenie zaznamenali aj inovatívne architektúry ako LightGBM. Vo svojom výskume zameranom na identifikáciu rizika zlyhania korporátnych dlhopisov aplikoval Zhao (2025) model LightGBM v spojení s optimalizačným algoritmom NSGA-II. Empirické testovanie ukázalo, že tento optimalizovaný ansámblový prístup dosahuje presnosť nad 85 % a prekonáva tak tradičné metódy, pričom exceluje vo vyhodnocovaní kritických rysov, akými sú ukazovatele obratu pohľadávok a ziskové marže.

Zhrnutie súčasnej odbornej literatúry naznačuje, že hoci pre akcie s nízkou volatilitou a stabilným trendom môže za určitých okolností používať aj klasická lineárna regresia, pre zachytenie komplexnej dynamiky, nelineárnych vzťahov a spracovanie rozsiahleho množstva technických indikátorov sa aktuálnym zlatým štandardom v oblasti klasického strojového učenia stávajú modely XGBoost a Random Forest.

1.3. Interpretovateľnosť modelov strojového učenia vo financiách

Narastajúca komplexita ansámblových algoritmov, akými sú XGBoost a Random Forest, prináša so sebou vážny metodologický problém ich interpretovateľnosti. Tieto metódy často v odbornej literatúre figurujú ako modely typu “čierna skrinka”. V kontexte finančného sektora a regulovaného auditu je neakceptovateľné prijímať investičné rozhodnutia výhradne na základe výstupov algoritmu bez pochopenia samotného rozhodovacieho procesu. Regulačné orgány aj investori vyžadujú presnú kvantifikáciu toho, aké konkrétne vstupné premenné viedli model k danej predikcii. Z tohto dôvodu sa integrálnou súčasťou aplikovaného strojového učenia stala analýza interpretovateľnosti.

Na riešenie problému transparentnosti sa v súčasnosti najčastejšie aplikujú analytické metódy ako SHAP (SHapley Additive exPlanations) a LIME (Local Interpretable Model-agnostic Explanations). Tieto matematické prístupy vychádzajú z teórie kooperatívnych hier a umožňujú presne vyčíslieť príspevok každého nezávislého parametra k finálnemu výsledku predikcie. V medzinárodnom výskume sa tejto problematike venoval napríklad Agarwal, ktorý vo svojej štúdii demonštroval, že aplikácia hodnôt SHAP na predikčný model XGBoost nielenže neznižuje jeho vynikajúcu predikčnú presnosť, ale poskytuje finančným analytikom kľúčový pohľad na to, ktoré konkrétne technické či fundamentálne indikátory najviac ovplyvňujú výslednú cenu aktíva (Agarwal, 2024). Zabezpečenie interpretovateľnosti modelov strojového učenia prostredníctvom týchto techník sa tak ukazuje ako nevyhnutný predpoklad pre ich dôveryhodné a bezpečné nasadenie do reálnej hospodárskej a obchodnej praxe.

1.4. Vplyv technických indikátorov a dátového šumu na presnosť

Dôležitým faktorom, ktorý zásadným spôsobom ovplyvňuje presnosť a výber ML modelov, je kvalita vstupných dát a množstvo aplikovaných technických indikátorov. Deep a kol. (2024) hodnotili výkonnosť regresných modelov Random Forest pri vysokofrekvenčnej predikcii cien akcií s využitím dátových sád obohatených o technické indikátory, akými sú Bollingerove pásma, exponenciálny kľzavý priemer či Fibonacciho návraty. Hoci implementácia týchto indikátorov vylepšila výkonnostné metriky očistené o riziko na tréningových dátach, modely následne výrazne zlyhávali pri generalizácii na testovacích vzorkách. Analýza dôležitosti príznakov odhalila, že primárne znaky založené výlučne na cene dosahovali vo vysokofrekvenčnom obchodovaní konzistentne lepšie výsledky ako odvodené technické indikátory, ktoré často generovali falošné signály a prispievali k preučeniu.

Pre redukciu tohto šumu a zlepšenie presnosti viacerí autori navrhujú konštrukciu hybridných prístupov aj v rámci samotného klasického strojového učenia. Nageswaran a Sankarasubramanian (2026) vo svojom výskume testovali historické akciové dáta (Open, High, Low, Close) a zistili, že kombinácia ansámblových stromových modelov a modelov založených na vektorových vzdialenostiach prináša väčšiu stabilitu a odolnosť voči trhovému šumu než použitie akéhokoľvek samostatného klasifikátora.

2. Ciel prace a metodika

Hlavným cieľom diplomovej práce je aplikácia vybraných algoritmov klasického strojového učenia pri predikcii vývoja cien finančných aktív a následná analýza porovnania ich predikčnej presnosti v dynamickom trhovom prostredí. Parciálnym cieľom v teoretickej časti je teoretické vymedzenie základných princípov a odborných pojmov nevyhnutných pre vytvorenie uceleného teoretického rámca v oblasti využívania analytických modelov vo financiách. Súčasťou tohto teoretického prieskumu je aj zhodnotenie aktuálneho stavu domáceho a zahraničného vedeckého poznania prostredníctvom rešerše odbornej literatúry so zameraním na doterajšie empirické komparácie lineárnych, vektorových a ansámblových metód.

Analytická časť diplomovej práce je zameraná na praktické testovanie a vyhodnotenie stanovených predikčných modelov priamo na historických dátach globálnych akciových trhov. Modelovanie bude prebiehať v programovacom prostredí jazyka Python, pričom sa s využitím špecializovaných knižníc pre dátovú vedu zrealizuje pedspracovanie údajov a natréovanie algoritmov, **akými sú lineárna regresia, Random Forest a XGBoost**. Preto za čiastkové ciele v praktickej časti považujeme nasledovné ciele:

- **Zber** a systematické pedspracovanie relevantných historických dát o vývoji cien vybraných akciových titulov prostredníctvom finančných rozhraní.
- **Konštrukcia** a implementácia vybraných technických indikátorov za účelom rozšírenia a obohatenia pôvodnej dátovej sady o premenné zachytávajúce trend a volatilitu.
- **Implementácia** a tréovanie vybraných modelov klasického strojového učenia s cieľom definovať ich optimálne hyperparametre pre účely predikcie časových radov.
- **Vyhodnotenie** predikčnej sily a presnosti jednotlivých algoritmov na základe kvantitatívnych metrík, akými sú stredná absolútna chyba, stredná kvadratická chyba a koeficient determinácie.
- **Porovnanie** výkonnosti regresných, vektorových a stromových metód v rôznych trhových podmienkach s cieľom identifikovať najvhodnejší predikčný model.
- **Aplikácia** metód vysvetliteľnej umelej inteligencie pre detailnú interpretáciu toho, akým spôsobom jednotlivé technické premenné ovplyvňujú finálne rozhodnutia modelov.

Naplnením týchto cieľov budeme schopní nielen identifikovať najpresnejší a efektívny algoritmus pre predikciu akciových trhov, ale aj poskytnúť transparentný a interpretovateľný rámec, ktorý podporí empiricky podložené investičné rozhodovanie v hospodárskej praxi.

3. Metodológia a architektúra predikčného systému **do 10 stran**

3.1 Výskumné ciele a formulácia problému

Zavádzanie metód strojového učenia do finančnej analýzy si vyžaduje jasné stanovenie výskumného problému a postupný prechod od tradičných ekonometrických prístupov k moderným dátovým modelom. Súčasné trhy sú totiž mimoriadne volatilné, plné nelineárnych vzťahov a náhodných výkyvov. Práve preto patrí predikcia cien finančných aktív medzi najkomplexnejšie výzvy, ktorým dnes analytici čelia.

V minulosti sa predikcie trhu spoliehali najmä na hypotézu efektívneho trhu (EMH). Tá predpokladá, že všetky dostupné informácie sa okamžite a úplne premietnu do ceny aktíva. Z toho vychádza princíp „náhodnej prechádzky“ (random walk) – myšlienka, že najlepším odhadom zajtrajšej ceny je tá dnešná a dlhodobo prekonávať trh je nemožné. Strojové učenie však tento striktný pohľad mení. Aj keď sú finančné dáta plné šumu, moderné algoritmy v nich dokážu odhaliť skryté nelineárne vzorce, na ktoré klasické ekonometrické modely ako ARIMA či GARCH jednoducho nestačia. Práve na prekonanie týchto limitov v práci navrhujeme predikčný systém založený na učení s učiteľom.

3.2 Architektúra systému a dátový tok

3.3 Zber dát a výber aktív

Surové cenové dáta nesú len obmedzenú informačnú hodnotu a modelom často nestačia na pochopenie trhovej dynamiky. Aby algoritmus dokázal rozoznať vznikajúce trendy, cykly a zmeny volatility, pôvodný dataset sa umelo rozširuje o nové premenné v procese nazývanom príznakové inžinierstvo (feature engineering). Tento proces zahŕňa konštrukciu technických indikátorov, integráciu externých dát a následný inteligentný výber tých najrelevantnejších parametrov.

1.5. Technické a štatistické indikátory

Do predikčného systému sú algoritmicky implementované viaceré overené trhové indikátory, z ktorých každý pomáha zachytiť inú vlastnosť analyzovaného aktíva:

- **RSI (Relative Strength Index):** Tento oscilátor meria rýchlosť a zmenu cenových pohybov, vďaka čomu model dokáže identifikovať, či je trh krátkodobo prekúpený alebo naopak predaný. Počíta sa na základe pomeru priemerných ziskov a priemerných strát

(označovaných ako RS) za stanovené časové okno:

$$RSI = 100 - \frac{100}{1 + RS}$$

- **MACD (Moving Average Convergence Divergence):** Ide o indikátor zameraný na sledovanie zotrvačnosti a hybnosti (momentum) trendu. Pomáha odhaliť zmeny v sile trendu sledovaním vzťahu medzi dvoma kľavými priermi. Vypočíta sa ako priamy rozdiel medzi krátkodobým (12-dňovým) a dlhodobým (26-dňovým) exponenciálnym kľavým priemerom (EMA) ceny:

$$MACD = EMA_{12}(Cena) - EMA_{26}(Cena)$$

- **Bollingerove pásma (Bollinger Bands):** Tieto pásma poskytujú modelu informáciu o aktuálnej trhovej volatilitate. Skladajú sa zo stredného kľavého priemeru (typicky 20-dňového) a dvoch okrajových páso. Okrajové pásy sú dynamicky umiestnené nad a pod stredným priemerom na základe pripočítania, resp. odpočítania násobku aktuálnej smerodajnej odchýlky.
- **ATR (Average True Range):** Zatiaľ čo Bollingerove pásma reagujú na uzatváracie ceny, indikátor ATR meria skutočnú čistú volatilitu trhu tak, že zohľadňuje aj cenové medzery (gapy) medzi jednotlivými obchodnými dňami. Modelu poskytuje absolútnu hodnotu priemerného denného pohybu ceny.

3.3.2 Alternatívne dáta a trhové sentimenty

Ceny akcií sa nevyvíjajú vo vákuu; reagujú na aktuálne udalosti, náladu v spoločnosti a globálne trendy. Z tohto dôvodu sa systém neobmedzuje len na cenové grafy, ale integruje aj alternatívne dátové zdroje, špecificky dáta o trendoch vo vyhľadávaní (Google Trends) a informácie z agregátorov správ.

Sledovanie frekvencie vyhľadávania určitých kľúčových slov poskytuje cenný indikátor spotrebiteľského a investorského záujmu ešte predtým, ako sa tento záujem prejaví na burze.¹ Napríklad vyhľadávanie slova „iPhone“ priamo súvisí s očakávaním tržieb spoločnosti Apple, kým frekvencia vyhľadávania skratky „AI“ odzrkadľuje širší investičný sentiment a ošial' okolo technologického sektora.² Systém do modelu zaraďuje aj kľúčové slová ako „elections“ (voľby), pretože pomáhajú zachytiť makroekonomickú neistotu a zmeny v rizikovom apetíte investorov.²

Tieto externé sentimentálne premenné dodávajú stromovým aj lineárnym modelom kontext, ktorý z čistých čísel nie je možné odvodiť.

3.3.3 Redukcia dimenzionality (Lasso L1)

Pridaním všetkých dostupných technických indikátorov, ich rôznych časových oneskorení a alternatívnych sentimentálnych dát vzniká mimoriadne široký dataset. Ak by sa všetky tieto premenné naraz vložili do učiaceho sa algoritmu, nevyhnutne by to viedlo k preučeniu (overfitting). Model by začal hľadať falošné pravidlá aj v náhodnom informačnom šume.

Na riešenie tohto problému sa v systéme aplikuje Lasso regresia, ktorá funguje ako zabudovaný filter pre výber vlastností (v implementácii reprezentovaná ako funkcia `select_features_lasso`). Lasso je forma lineárnej regresie s L1 regularizáciou. Upravuje štandardnú chybovú funkciu modelu tak, že do nej pridáva penalizačný člen. Tento člen prísne trestá model za každý použitý parameter (váhu), pričom trest je úmerný absolútnej hodnote tejto váhy:

$$\text{Cost} = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^m |w_j|$$

V tomto vzorci λ predstavuje silu penalizácie a w_j sú koeficienty (váhy) jednotlivých vstupných premenných. Dôvod, prečo táto konkrétna rovnica redukuje dimenzionalitu, spočíva v tvare L1 penalty. Na rozdiel od iných metód, ktoré váhy iba znižujú, Lasso vďaka absolútnej hodnote dokáže zraziť váhy menej užitočných indikátorov presne na nulu. Systém tak automaticky identifikuje a vyradí premenné, ktoré neprispievajú k presnosti predikcie. Výsledkom je menší, čistejší a oveľa stabilnejší súbor prediktorov, ktorý sa následne posúva hlavným algoritmom strojového učenia.

3.4 Hodnotiace metriky

Vzorcie modelov

4. Implementácia strojového učenia

4.1 Dátová základna

Predspracovanie

Dovod vyberu akcie/indexu.

4.2 Spôsoby ako sa to robilo

Ako sa to robilo pre vybranú spoločnosť

4.3 Popísanie výsledkov

Podobne aj pre iné spoločnosti a sú v prílohe

5.

6. zaver

Bez cisel

Zoznam použitej literatúry

- Andrika, M. Y., & Rahardi, M. (2025). Comparative Study of Linear Regression, SVR, and XGBoost for
- Agarwal, R. (2024). Financial Performance Prediction and Stability Analysis Using SHAP-Enhanced Machine Learning Models.
- Andrika, M. Y., & Rahardi, M. (2025). Comparative Study of Linear Regression, SVR, and XGBoost for Stock Price Prediction After a Stock Split. *Journal of Applied Informatics and Computing*.
- Cibuľa, M. (2022). Strojové učenie ako srdce umelej inteligencie pre investora. *Finančné trhy*, 1.
- Deep, A., Monico, C., Shirvani, A., Rachev, S., & Fabozzi, F. J. (2024). Assessing the Impact of Technical Indicators on Machine Learning Models for Stock Price Prediction.
- Deswal, V. (2023). Stock Price Prediction of AAPL Stock by Using Machine Learning Techniques: A Comparative Study. *12th International Conference on System Modeling & Advancement in Research Trends*.
- Jin, X., & Yi, C. (2023). Stock price prediction using multiple machine learning algorithms. *ICBBEM*.
- Kim, H., Cho, H., & Ryu, D. (2020). Corporate Default Predictions Using Machine Learning: Literature Review. *Sustainability*, 12(16), 6325.
- Kristanti, F. T., Febrianta, M. Y., Salim, D. F., Riyadh, H. A., Sagama, Y., & Beshr, B. A. H. (2024). Financial distress prediction using ensemble machine learning models. *Journal of Infrastructure, Policy and Development*.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. John Wiley & Sons.
- MDPI. (2020). Predicting Financial Distress of Slovak Enterprises: Comparison of Selected Traditional and Learning Algorithms Methods. *Sustainability*.
- MDPI. (2024). Modeling and Forecasting the Morocco Stock Index 20 Using Machine Learning Methods. *Forecasting*, 7(1), 39.

- Nageswaran, M. K., & Sankarasubramanian, R. (2026). Simple Stock Price Prediction Using Machine Learning. *The Bioscan*, 21(1), 393-401.
- Panggabean, & Widyasari. (2023). Performance Comparison of Random Forest Regression, SVR Models in Stock Price Prediction. *Jurnal Pilar Nusa Mandiri*.
- Raya, a kol. (2022). Stock price prediction utilizing machine learning algorithms.
- Shi, H. (2024). Tesla Stock Price Forecast Based on ARIMA Model and Machine Learning Techniques.
- Wang, H. (2023). Stock Price Prediction Based on Machine Learning. Atlantis Press.
- Wang, H. (2025). Stock Return Prediction Based on Linear Regression, Random Forest and XGBoost. Atlantis Press.
- Zhao, Y. (2025). Research on Interpretable Machine Learning Models for Identifying Corporate Bond Default Risk. *Population, Resources & Environmental Economics*, 6, 38-45.
- Zubair, M., a kol. (2024). Machine Learning Insights into Retail Sales Prediction: A Comparative Analysis of Algorithms.

Prílohy